

形式语言与 自动机

人工智能学院 刘咏彬 liuyb@bupt.edu.cn



文法的构造

- 用语法表达语言是语言处理中的重要一步。Expressing language with **Grammar** is an important step in language processing.
- 没有直接的方法来构造语法，这取决于构造函数的经验。There is no direct method to construct grammar, which depends on the constructor's experience.
- 当给出语法时，很难清楚地陈述语法定义的语言特征。When a grammar is given, it is difficult to clearly state the language characteristics defined by the grammar.
- 本节给出了一些典型的语言语法。Some typical language grammars are given in this section.

例 2-9

例2-9 构造文法G，使 $L(G)=\{0, 1, 00, 11\}$

- 将文法的开始符号定义为这4个句子。
 - $G_1=(\{S\}, \{0, 1\}, \{S \rightarrow 0, S \rightarrow 1, S \rightarrow 00, S \rightarrow 11\}, S)$
- 先用变量A表示0，用变量B表示1。
 - $G_2=(\{S, A, B\}, \{0, 1\}, \{S \rightarrow A, S \rightarrow B, S \rightarrow AA, S \rightarrow BB, A \rightarrow 0, B \rightarrow 1\}, S)$
- 基于 G_2 ，考虑“规范性”问题。
 - $G_3=(\{S, A, B\}, \{0, 1\}, \{S \rightarrow 0, S \rightarrow 1, S \rightarrow 0A, S \rightarrow 1B, A \rightarrow 0, B \rightarrow 1\}, S)$

G_3 中产生式右部的第一个符号为终极符号，这种形式的文法对相应语言的计算机处理是非常方便的。

例 2-9

- 可以在V、T中增加一些元素，以获得“不同的”文法。
 - $G_4 = (\{S, A, B, C\}, \{0, 1, 2\}, \{S \rightarrow A, S \rightarrow B, S \rightarrow AA, S \rightarrow BB, A \rightarrow 0, B \rightarrow 1\}, S)$
 - $G_5 = (\{S, A, B, C\}, \{0, 1, 2\}, \{S \rightarrow A, S \rightarrow B, S \rightarrow AA, S \rightarrow BB, A \rightarrow 0, B \rightarrow 1, CACS \rightarrow 21, C \rightarrow 11, C \rightarrow 2\}, S)$

上述文法产生的语言都是 $\{0, 1, 00, 11\}$

$$L(G_1) = L(G_2) = L(G_3) = L(G_4) = L(G_5)$$

由此可见，一个语言可以由多个文法产生。

等价

- 定义 2-5：等价(equivalence)

- 设有两个文法 G_1 和 G_2 ，如果 $L(G_1) = L(G_2)$ ，则称 G_1 与 G_2 等价。

- 约定：对一个文法，为了简化文法的表达，可以只列出该文法的所有产生式，例如：

$G_1: S \rightarrow 0|1|00|11$

$G_2: S \rightarrow A|B|AA|BB, A \rightarrow 0, B \rightarrow 1$

$G_3: S \rightarrow 0|1|0A|1B, A \rightarrow 0, B \rightarrow 1$

$G_4: S \rightarrow A|B|AA|BB, A \rightarrow 0, B \rightarrow 1$

$G_5: S \rightarrow A|B|BB, A \rightarrow 0, B \rightarrow 1, CACS \rightarrow 21, C \rightarrow 11, C \rightarrow 2$

对简化文法的理解：第一个产生式左部符号为起始符号；所有产生式中出现的变量构成变量集合 V ，所有终结符构成终结符集合 T ，所有产生式构成产生式集合 P 。

例 2-10

例 2-10 几个典型文法

- $L = \{0^n | n \geq 1\}$

$G_6: S \rightarrow 0 | 0S$

- $L = \{0^n | n \geq 0\}$

$G_7: S \rightarrow \varepsilon | 0S$

- $L = \{0^{2n}1^{3n} | n \geq 0\}$

$G_8: S \rightarrow \varepsilon | 00S111$

例 2-11

- 例2-11 构造文法 G_9 , 使 $L(G_9)=\{w|w \in \{a, b, \dots, z\}^+\}$ 。

$G_9: S \rightarrow A|AS$

$A \rightarrow a|b|c|d|e|f|g|h|i|j|k|l|m|n|o|p|q|r|s|t|u|v|w|x|y|z$

- 注意:

✓ 可以用 $S \rightarrow A|AS$ 生成 A^n 。

× 不可以用 $A \rightarrow a|b|c|\dots|z$ 表示 $A \rightarrow a|b|c|d|e|f|g|h|i|j|k|l|m|n|o|p|q|r|s|t|u|v|w|x|y|z$

× 不可以用 $A \rightarrow a^8$ 表示 $A \rightarrow aaaaaaaaa$ 。

× 不可以用 $A \rightarrow a^n$ 表示A可以产生任意多个a。

补充提醒: 推导过程中, 同样的变量可以选择不同的候选式, 例如:

$S \rightarrow AS | A$

$A \rightarrow a | b | c$

$S \Rightarrow^* AAA \Rightarrow^* abc$

例 2-12

- 例2-12 构造文法 G_{10} , 使
 - $L(G_{10}) = \{ww^T | w \in \{0, 1, 2, 3\}^+\}$ 。

- 分析:

$\{ww^T | w \in \{0, 1, 2, 3\}^+\}$ 的句子特点

设 $w = a_1 a_2 \dots a_n$, 从而有 $w^T = a_n \dots a_2 a_1$, 故 $ww^T = a_1 a_2 \dots a_n a_n \dots a_2 a_1$

正数第 i 个符号与倒数第 i 个符号相同。

递归地定义 L

- (1) 对 $\forall a \in \{0, 1, 2, 3\}$, $aa \in L$;
- (2) 如果 $x \in L$, 则对 $\forall a \in \{0, 1, 2, 3\}$, $axa \in L$;
- (3) L 中不含不满足(1)、(2)任何其他的串。

例 2-12

根据递归定义中的第一条，有如下产生式组：

$$S \rightarrow 00 \mid 11 \mid 22 \mid 33$$

再根据递归定义第二条，又可得到如下产生式组：

$$S \rightarrow 0S0 \mid 1S1 \mid 2S2 \mid 3S3$$

从而，

$$G_{10}: S \rightarrow 00 \mid 11 \mid 22 \mid 33 \mid 0S0 \mid 1S1 \mid 2S2 \mid 3S3$$

例 2-13 十进制有理数的文法构造

- 例2-13 构造文法 G_{12} ，使 $L(G_{12})=\{w|w\text{是十进制有理数}\}$ 。
- 设 S 为开始符号，无符号有理数表示为 R 则可得到产生式：
 - $S \rightarrow R \mid +R \mid -R$
- R 又可以划分为整数（ N ）、带小数（整数部分不为0： B ）和纯小数（整数部分为0： P ），即得到产生式：
 - $R \rightarrow N \mid B \mid P$
- 带小数是有“.”隔开的整数部分和小数部分组成，其中整数部分就是无符号整数 N ，小数部分用 D 表示，即得到产生式：
 - $B \rightarrow N.D$
- 纯小数产生式为： $P \rightarrow 0.D$

例 2-13 十进制有理数的文法构造

- 对于无符号整数N，对应字母表 $\{0,1,2,3,4,5,6,7,8,9\}$ 上的语言
 - 如果N为个位数，可以为1-9任意一个
 - 如果N为两位数，则十位数字不应该为0
 - 如果N为百位数，则百位数不应该为0
 - 所以考虑构造以下产生式来满足以上要求：

$N \rightarrow 0 | AM$

$A \rightarrow 1 | 2 | 3 | 4 | 5 | 6 | 7 | 8 | 9$

$M \rightarrow \varepsilon | 0M | 1M | 2M | 3M | 4M | 5M | 6M | 7M | 8M | 9M$ (M代表字母表 $\{0,1,2,3,4,5,6,7,8,9\}$ 上生成的所有句子)

例 2-13 十进制有理数的文法构造

- 对于小数部分D，要求与N正好相反
 - 小数部分为0时，表示为仅有一个0
 - 最低位小数位不能为0
 - 按照以上要求得到产生式：

$D \rightarrow 0 \mid MA$

$A \rightarrow 1 \mid 2 \mid 3 \mid 4 \mid 5 \mid 6 \mid 7 \mid 8 \mid 9$

$M \rightarrow \varepsilon \mid 0M \mid 1M \mid 2M \mid 3M \mid 4M \mid 5M \mid 6M \mid 7M \mid 8M \mid 9M$

例 2-13 十进制有理数的文法构造

将上述产生式整理到一起，得到十进制有理数文法表示为：

$$S \rightarrow R \mid +R \mid -R$$

$$R \rightarrow N \mid B \mid P$$

$$B \rightarrow N.D$$

$$P \rightarrow 0.D$$

$$N \rightarrow 0 \mid AM$$

$$D \rightarrow 0 \mid MA$$

$$A \rightarrow 1 \mid 2 \mid 3 \mid 4 \mid 5 \mid 6 \mid 7 \mid 8 \mid 9$$

$$M \rightarrow \varepsilon \mid 0M \mid 1M \mid 2M \mid 3M \mid 4M \mid 5M \mid 6M \mid 7M \mid 8M \mid 9M$$

例 2-13 十进制有理数的文法构造

由于N可以推导出0，所以 $P \rightarrow 0.D$ 包含在 $B \rightarrow N.D$ 产生式中，可以去掉与P有关的产生式，得到十进制有理数文法表示为：

G_{12} : $S \rightarrow R \mid +R \mid -R$

$R \rightarrow N \mid B$

$B \rightarrow N.D$ （当 $N \Rightarrow 0$ 时，B能够推导出纯小数）

$N \rightarrow 0 \mid AM$

$D \rightarrow 0 \mid MA$

$A \rightarrow 1 \mid 2 \mid 3 \mid 4 \mid 5 \mid 6 \mid 7 \mid 8 \mid 9$

$M \rightarrow \varepsilon \mid 0M \mid 1M \mid 2M \mid 3M \mid 4M \mid 5M \mid 6M \mid 7M \mid 8M \mid 9M$

例 2-14 构造产生算术表达式的文法

• 例2-14 构造产生算术表达式的文法：

(1) 基础：常数是算术表达式，变量是算术表达式；

(2) 归纳：如果 E_1 、 E_2 是表达式，则 $+E_1$ 、 $-E_1$ 、 E_1+E_2 、 E_1-E_2 、 $E_1 * E_2$ 、 E_1 / E_2 、 $E_1 ** E_2$ 、 $\text{Fun}(E_1)$ 是算术表达式。其中Fun为函数名。

(3) 只有满足(1)和(2)的才是算术表达式。

$G_{13}: E \rightarrow \text{id} | c | +E | -E | E+E | E-E | E * E | E / E | E ** E | \text{Fun}(E)$

举例： $x+y*z/4$ $5.0 + \text{sqrt}(4.0)$

例 2-15 $\{a^n b^n c^n | n \geq 1\}$

- 例2-15 构造产生语言 $\{a^n b^n c^n | n \geq 1\}$ 的文法。

一种错误答案:

文法 $G = (\{S_1\}, \{a, b\}, \{S_1 \rightarrow ab \mid aS_1b\}, S_1)$

产生的语言 $\{a^n b^n \mid n \geq 1\}$ 形式上看起来与语言 $\{a^n b^n c^n \mid n \geq 1\}$ 比较接近。

$G = (\{S_2\}, \{c\}, \{S_2 \rightarrow c \mid cS_2\}, S_2)$ 产生的语言是 $\{c^n \mid n \geq 1\}$ 。

$\{a^n b^n c^n \mid n \geq 1\} \neq \{a^n b^n \mid n \geq 1\} \{c^n \mid n \geq 1\}$

错误总结: $S \rightarrow S_1 S_2$

$S_1 \rightarrow ab \mid aS_1b$

$S_2 \rightarrow c \mid cS_2$

不能产生语言 $\{a^n b^n c^n \mid n \geq 1\}$, 而是产生语言 $\{a^n b^n \mid n \geq 1\} \{c^n \mid n \geq 1\}$

例 2-15 $\{a^n b^n c^n | n \geq 1\}$

另一种错误答案:

$$S \rightarrow abc \mid aSbc$$

产生的语言为:

$$\{a^n (bc)^n \mid n \geq 1\}$$

焦点: b 和 c 的位置错误。

正确答案:

$$\begin{aligned} G_{14}: \quad & S \rightarrow aBC \mid aSBC, \\ & CB \rightarrow BC \\ & aB \rightarrow ab \\ & bB \rightarrow bb \\ & bC \rightarrow bc \\ & cC \rightarrow cc \end{aligned}$$

$$\begin{aligned} G_{14}': \quad & S \rightarrow abc \mid aSBc, \\ & bB \rightarrow bb \\ & cB \rightarrow Bc \end{aligned}$$

文法 G_{14} 与 G_{14}' 均符合题目要求, 二者等价。

回顾

- 1、掌握常见语言的语法构造。
- 2、理解语法构造的思路。
- 3、掌握标识符、十进制有理数、算术表达式等的语法构造。

提问时间