


形式语言与 自动机

人工智能学院 刘咏彬 liuyb@bupt.edu.cn



语言识别 Language Recognition

- 语言识别是语言处理中的一项重要任务。 Language recognition is an important task in language processing.
- 文法为语言描述提供了一种有效的手段，但是在使用文法机制识别句子时会出现"回溯"的问题，这对语言识别的效率有很大的影响。 *Grammar* provides an effective means for language description, but the problem of "**backtracking**" will occur when using grammar mechanism to recognize sentences, which has a great impact on the efficiency of language recognition.

语言识别 Language Recognition

- 给定文法 $G = (V, T, P, S)$, $L(G) = \{w \mid w \in T^* \text{ 且 } S \Rightarrow^* w\}$
- 问题：给出字符串 w ，判断 w 是否为文法 G 产生的句子？即 $S \Rightarrow^* w$ 在 G 中是否成立。
 - 如果成立：需要找出从 S 出发，生成 w 的推导过程；或者，从 w 出发，归约到 S 。
 - 如果不成立：证明从 S 出发不存在任何推导过程能生成 w ；或者，从 w 出发，不能归约为 S 。

语言识别 Language Recognition

- $G = (V, T, P, S)$, $L(G) = \{w \mid w \in T^* \text{ 且 } S \Rightarrow^* w\}$
- 任务：给出字符串 w ，判断 w 是否为文法 G 产生的句子？即 $S \Rightarrow^* w$ 在 G 中是否成立。
 - 如果成立：需要找出从 S 出发，生成 w 的推导过程；或者，从 w 出发，归约到 S ——一次推导不成功，不能说明 w 不是 $L(G)$ 中的句子，还需要做下一次推导尝试；
 - 如果不成立：证明从 S 出发不存在任何推导过程能生成 w ；或者，从 w 出发，不能归约为 S ——只有所有可能的推导过程全部尝试后，都无法得到 w ，才可以下结论 w 不是 $L(G)$ 中的句子。

注意：回溯过程有大量的计算，将对语言识别系统的效率产生很大的影响。

回溯例子 Backtracking Example


- Grammar G:

$S \rightarrow aA|aB$

$A \rightarrow aA|c$

$B \rightarrow aB|d$


- $aaad \in L(G)$?



Result: $aaad \in L(G)$


语言识别 Language Recognition

- 有穷自动机 (FA) 的形式模型，在语言识别中具有优势。 Another formal model called *finite automata(FA)* is proposed, which plays an advantage in language recognition.
- 有穷自动机具有一组状态，其"控制"从一个状态移动到另一个状态以响应外部"输入"。 A finite automaton has a set of **states**, its "**control**" moves from state to state in response to external "**inputs**".
- FA 通常由 **状态转换图** 表示。 FA is often represented by a state transition diagram.



有穷自动机例子 FA Example

- $L = \{a^n c | n \geq 1\} \cup \{a^n d | n \geq 1\}$ $aaad \in L(G)?$




识别过程：

- (1) FA从起始状态 q_0 开始执行；
- (2) 看到第一个 a ，进入 q_1 状态；
- (3) 看到第二个 a ，还在 q_1 状态；
- (4) 看到第三个 a ，还在 q_1 状态；
- (5) 看到 d ，进入 q_3 状态；
- (6) 因为 q_3 属于终止状态，并且 d 之后没有其他字符了，所以判断该句子是 $L(G)$ 的句子。

有穷自动机例子 FA Example

- $L = \{a^n c | n \geq 1\} \cup \{a^n d | n \geq 1\}$ $aaaa \in L(G)?$



识别过程:


- (1) FA从起始状态 q_0 开始执行;
- (2) 看到第一个a, 进入 q_1 状态;
- (3) 看到第二个a, 还在 q_1 状态;
- (4) 看到第三个a, 还在 q_1 状态;
- (5) 看到第四个a, 还在 q_1 状态;
- (6) 句子已经识别完成, 因为 q_1 不是终止状态, 所以判断该句子不是 $L(G)$ 的句子。

有穷自动机 Finite Automaton


- 当使用FA模型识别语言时，如果它可以**从开始状态开始并到达结束状态**，则输入字符串是给定语言中的句子;否则，输入字符串不是语言中的句子。 When using FA model to recognize languages, if it can start from the start state and reach the end state, the input string is a sentence in a given language; otherwise, the input string is not a sentence in the language.
- FA模型在语言句子识别过程中非常清晰简洁。 FA model is very clear and concise in the process of language sentence recognition.

有穷自动机五要素 Elements of Finite Automaton

- (1)有穷状态集;
- (2)一个开始状态;
- (3)一个或多个终止状态;
- (4)输入字符集合;
- (5)状态转移的控制规则;



有穷自动机的物理模型 Finite Automaton Physical Model



- 系统的每一个动作由三个节拍构成：
 - (1) 读入读头正注视的字符；
 - (2) 根据当前状态和读入的字符改变有穷控制器的状态；
 - (3) 将读头向右移动一格。

回顾

- 1、基于文法的语言识别有什么问题？
- 2、基于FA识别语言的方法。
- 3、FA中有哪些要素。