



智能计算系统


第三章 深度学习应用

北京邮电大学人工智能学院
何召锋 徐振博 项刘宇

提纲

- ▶ 适合图像处理的卷积神经网络
- ▶ 适合语音/文本处理的循环神经网络
- ▶ 从深度学习到大模型
 - ▶ LLM模型结构
 - ▶ 预训练及微调
 - ▶ 面向图像处理的大模型
 - ▶ 智能体系统
- ▶ 神经网络量化
- ▶ 本章小结

Transformer在图像处理中的应用



提纲


- ▶ 面向图像处理的大模型
 - ▶ 面向目标检测/图像分类的大模型
 - ▶ 面向图像生成的大模型
 - ▶ 视觉-语言模型

提纲

- ▶ 面向图像处理的大模型
 - ▶ 面向目标检测/图像分类的大模型
 - ▶ 面向图像生成的大模型
 - ▶ 视觉-语言模型

DETR (Detection Transformer)

- 将目标检测任务问题视为**集合预测**问题。摆脱了传统目标检测方法中许多手工设计的部件，如非极大值抑制（NMS）、锚框（anchor）的生成。





- ① CNN的backbone用于进行特征提取；
- ② 变成特征序列输入到transformer的编解码器；
- ③ 前馈网络（FFN）输出最终预测结果。

Carion, N., Massa, F., Synnaeve, G., Usunier, N., Kirillov, A., Zagoruyko, S. End-to-End Object Detection with Transformers. ECCV 2020.


DETR (Detection Transformer)

► 编码器-解码器结构




DETR (Detection Transformer)

► 编码器-解码器结构



DETR (Detection Transformer)

- 将目标检测任务问题视为**集合预测**问题。摆脱了传统目标检测方法中许多手工设计的部件，如非极大值抑制（NMS）、锚框（anchor）的生成。



- 训练时：通过匈牙利算法（Hungarian Matching）实现预测集合与真值的一一对应
- 推理时：每个object query直接负责预测一个物体（或空）

Carion, N., Massa, F., Synnaeve, G., Usunier, N., Kirillov, A., Zagoruyko, S. End-to-End Object Detection with Transformers. ECCV 2020.

ViT (Vision Transformer)

- ▶ Transformer在计算机视觉中的难点
 - ▶ 把什么作为Transformer的token? 是像素还是图像块?
 - ▶ 对于256*256大小的图像, 一共有62500个像素, 如果都当作token, 需要3906250000次计算!



Dosovitskiy A, Beyer L, Kolesnikov A, et al. An image is worth 16x16 words: Transformers for image recognition at scale. ICLR2021.

ViT (Vision Transformer)

- ▶ Transformer在计算机视觉中的难点
 - ▶ token vs. 像素点
- ▶ Vision Transformer的改进
 - ▶ 像素点 → 图像块

AN IMAGE IS WORTH 16X16 WORDS: TRANSFORMERS FOR IMAGE RECOGNITION AT SCALE

**Alexey Dosovitskiy^{*,†}, Lucas Beyer^{*}, Alexander Kolesnikov^{*}, Dirk Weissenborn^{*},
Xiaohua Zhai^{*}, Thomas Unterthiner, Mostafa Dehghani, Matthias Minderer,
Georg Heigold, Sylvain Gelly, Jakob Uszkoreit, Neil Houlsby^{*,†}**

^{*}equal technical contribution, [†]equal advising

Google Research, Brain Team

{adosovitskiy, neilhoulby}@google.com

ViT (Vision Transformer)

- ▶ Transformer在计算机视觉中的难点
 - ▶ 像素作为词元，输入序列太长。例如， 224×224 的图片变成50176的序列，为BERT的100倍



像素




图像块

Dosovitskiy A, Beyer L, Kolesnikov A, et al. An image is worth 16x16 words: Transformers for image recognition at scale. ICLR2021.

ViT (Vision Transformer)

- ▶ Transformer在计算机视觉中的难点
 - ▶ 像素作为词元，输入序列太长。例如， 224×224 的图片变成50176的序列，为BERT的100倍
- ▶ 将图片分类问题转换为序列问题




Dosovitskiy A, Beyer L, Kolesnikov A, et al. An image is worth 16x16 words: Transformers for image recognition at scale. ICLR2021.

ViT (Vision Transformer)

具体流程

- ①将图像划分为固定大小的Patches
- ②将Patches展平成一维向量
- ③添加Position embedding
- ④添加Class token
- ⑤输入Transformer Encoder
- ⑥分类



Dosovitskiy A, Beyer L, Kolesnikov A, et al. An image is worth 16x16 words: Transformers for image recognition at scale. ICLR2021.

Vision Transformer


	Ours-JFT (ViT-H/14)	Ours-JFT (ViT-L/16)	Ours-I21k (ViT-L/16)	BiT-L (ResNet152x4)	Noisy Student (EfficientNet-L2)
ImageNet	88.55 ± 0.04	87.76 ± 0.03	85.30 ± 0.02	87.54 ± 0.02	88.4/88.5*
ImageNet ReaL	90.72 ± 0.05	90.54 ± 0.03	88.62 ± 0.05	90.54	90.55
CIFAR-10	99.50 ± 0.06	99.42 ± 0.03	99.15 ± 0.03	99.37 ± 0.06	—
CIFAR-100	94.55 ± 0.04	93.90 ± 0.05	93.25 ± 0.05	93.51 ± 0.08	—
Oxford-IIIT Pets	97.56 ± 0.03	97.32 ± 0.11	94.67 ± 0.15	96.62 ± 0.23	—
Oxford Flowers-102	99.68 ± 0.02	99.74 ± 0.00	99.61 ± 0.02	99.63 ± 0.03	—
VTAB (19 tasks)	77.63 ± 0.23	76.28 ± 0.46	72.72 ± 0.21	76.29 ± 1.70	—
TPUv3-core-days	2.5k	0.68k	0.23k	9.9k	12.3k

► 问题

- 图像尺度不固定，变化范围非常大
- 基于全局计算注意力，因此计算复杂度非常高

Swin Transformer


- ▶ 基于移动窗口的分层 Transformer 结构
- ▶ 和ViT的主要区别在于：划分windows，只在window内做self-attention



- ▶ 可以作为计算机视觉领域的通用骨干网络，在图像分类、目标检测、图像分割等不同的任务上都取得当时最好的性能



Swin Transformer

- 随着block堆叠，逐渐增加windows大小，增加尺度信息



Swin Transformer

- ▶ 随着block堆叠，逐渐增加windows大小，增加尺度信息
- ▶ 交替使用regular window和shifted window，增加window之间的联系。其中shifted window指将window边界向右下方移动window大小的一半



提纲

- ▶ 面向图像处理的大模型
 - ▶ 面向目标检测/图像分类的大模型
 - ▶ 面向图像生成的大模型
 - ▶ 视觉-语言模型

图像生成

➤ 图像识别



判别模型



Cat ✓
Dog ✗

- 网络学习到的是数据的模式/特征

➤ 图像生成




生成模型



- 网络学习到的是数据的分布

生成模型


- 同类别图像可以看作是一组数据分布 p_{data}
- 生成模型：从概率分布中找出一个与 p_{data} 相近的数据分布 p_{θ} 。然后从所学分布 p_{θ} 中采样出新的样本



生成模型


生成模型大致分类：

- ▶ GAN
- ▶ VAE
- ▶ Flow-based
- ▶ Diffusion



生成对抗网络GAN

- ▶ 2014年, Ian Goodfellow提出生成式对抗网络GAN
 - ▶ Goodfellow I J, Pouget-Abadie J, Mirza M, et al. Generative adversarial nets. NeurIPS'2014.
 - ▶ 20年来机器学习领域最酷的想法——Yann LeCun
- ▶ 解决的问题: 从训练样本中学习出新样本。为无监督、预测学习提供算法框架




<https://blog.openai.com/generative-models/>

GAN学习到了真实样本集的数据分布


生成对抗网络GAN

- ▶ 模型由两部分组成
 - ▶ **生成器**（伪造者）：找出观测数据内部的统计规律，尽可能生成能够以假乱真的样本，使判别网络输出接近0.5，难以区分真假。
 - ▶ **判别器**（警察）：判断输入数据是来自真实样本集还是生成样本集。如果输入是真样本，输出接近1；如果输入是生成样本，输出接近0。



GAN训练过程

- 更新判别网络权值参数，使其能分清真假样本。



- 更新生成网络权值参数，使其生成的假样本被判别网络识别为真样本。

GAN训练过程

▶ 优化判别器D

$$J^{(D)} = -\mathbb{E}_{\mathbf{x} \sim p_{data}(\mathbf{x})}[\log(D(\mathbf{x}))] - \mathbb{E}_{\mathbf{z} \sim p_{\mathbf{z}}(\mathbf{z})}[\log(1 - D(G(\mathbf{z})))]$$

- ▶ 优化目标：输入真样本 $\mathbf{x}$ 时，输出接近1；输入生成样本 $G(\mathbf{z})$ 时，输出接近0

▶ 优化生成器G

$$J^{(G)} = \mathbb{E}_{\mathbf{z} \sim p_{\mathbf{z}}(\mathbf{z})}[\log(1 - D(G(\mathbf{z})))]$$

- ▶ 优化目标：生成的假样本 $G(\mathbf{z})$ ，被判别器判断为接近1，即 $(1 - D(G(\mathbf{z})))$ 越小越好

▶ GAN训练是极小极大博弈问题（或零和博弈）

$$\min_G \max_D V(D, G) = -J^{(D)} = \mathbb{E}_{\mathbf{x} \sim p_{data}(\mathbf{x})}[\log(D(\mathbf{x}))] + \mathbb{E}_{\mathbf{z} \sim p_{\mathbf{z}}(\mathbf{z})}[\log(1 - D(G(\mathbf{z})))]$$

生成对抗网络GAN

- ▶ GAN有一个整体的损失函数，而不需要对生成网络和对抗网络分别指定具体的损失函数，有较强的通用性。

- ▶ 问题

- ▶ 梯度消失：当判别器以高置信度成功判断生成器生成的样本为假样本时，生成器的梯度会消失。训练早期， $\log(1 - D(G(z)))$ 会饱和


- ▶ 应对方法：修改生成器的代价函数

$$J^{(G)} = -E_{z \sim p_z(z)}[\log(D(G(z)))]$$

- ▶ 模式崩溃：生成器只生成几种模式的样本，生成样本缺乏多样性

模式崩溃(mode collapse)

- ▶ 产生原因： GAN的损失函数使判别器假样本的惩罚是巨大的，一旦生成的某一类假样本成功骗过判别器，生成器就趋向于生成相似的样本。




MNIST数据集的t-SNE图，10个团簇对应10种模式。

模式崩溃时，只生成其中的几种模式，生成样本缺乏多样性。

van der Maaten, L. & Hinton, G. Visualizing Data using t-SNE. *Journal of Machine Learning Research*, **2008**, 2579-2605

- ▶ 应对方法（WGAN）：采用更加平滑的损失函数，参见Wasserstein GAN

GAN相关研究




<https://github.com/hindupuravinash/the-gan-zoo>

GAN结构

- ▶ 卷积GAN
 - ▶ DCGAN: 将GAN中全连接神经网络扩展到卷积神经网络
 - ▶ ResGAN: 图像恢复, ResNet
 - ▶ SRGAN: 超分辨率, ResNet
 - ▶ CycleGAN: 图像转换
- ▶ 条件GAN
 - ▶ CGAN
 - ▶ InfoGAN
- ▶ 集成推断模型的GAN
 - ▶ BiGAN
- ▶ 对抗自编码器
 - ▶ VAE-GAN

DCGAN

- ▶ 用卷积神经网络取代全连接神经网络
 - ▶ 判别器用卷积，生成器用转置卷积，来取代所有池化层，做空间下采样和上采样
 - ▶ 生成器和判别器使用batchnorm，进行深度神经网络训练，防止模式崩溃
 - ▶ 生成器用Tanh作为输出的激活函数，用ReLU作为其它层的激活函数
 - ▶ 判别器的所有层都使用LeakyReLU作为激活函数
 - ▶ 首次证明深度卷积网络可以稳定训练 GAN




Radford, A.; Metz, L. & Chintala, S. Unsupervised Representation Learning with Deep Convolutional Generative Adversarial Networks, ICLR, 2016.

Conditional GAN (cGAN)

- ▶ 原始GAN生成器的输入是随机噪声，因此输出数据的模式是不可控的。如果在输入中增加类别条件，可以获得预期的输出。

input :
0
1
2
3

output :



input :




output :



Conditional GAN (cGAN)



- ▶ cGAN: 在生成网络的输入 $\mathbf{z}$ 的基础上加上辅助信息 $\mathbf{y}$ （类别标签或其它模态数据）；在判别网络的输入 $\mathbf{x}$ 的基础上也加上 $\mathbf{y}$ 。判别网络在考虑 $\mathbf{y}$ 的前提下判定 $\mathbf{x}$ 是否为真样本。

$$\min_G \max_D V(D, G) = \mathbb{E}_{\mathbf{x} \sim p_{\text{data}}(\mathbf{x})} [\log D(\mathbf{x}|\mathbf{y})] + \mathbb{E}_{\mathbf{z} \sim p_z(\mathbf{z})} [\log(1 - D(G(\mathbf{z}|\mathbf{y})))].$$




CycleGAN

- ▶ CycleGAN: 不需要成对的训练数据, 通过循环一致性损失实现风格迁移或域转换。
- ▶ 双向循环一致性: 引入“循环损失”, $A \rightarrow B \rightarrow A$ 应还原原图, 保证语义不变



GAN应用

- ▶ 人脸生成
- ▶ 风格转换
- ▶ Super resolution
- ▶ ...




GAN zoo: <https://deephunt.in/the-gan-zoo-79597dc8c347>
GAN代码合集: <https://github.com/zhangqianhui/AdversarialNetsPapers>
GAN应用合集: <https://github.com/nashory/gans-awesome-applications>

自编码器

▶ 自编码器

- ▶ 无监督学习的前馈神经网络，学习恒定解码函数来重构原始输入
- ▶ 编码器：将高维输入转换为低维的隐向量（隐藏层），提取图像特征
- ▶ 解码器：从隐向量重构恢复出原始数据 $\hat{x}$




- ▶ 应用：数据压缩，特征提取，数据去噪，生成模型等

变分自编码器 (VAE)

▶ VAE

- ▶ 编码器：将输入映射到一个概率分布上，而不是一个固定的向量（用 μ_x, σ_x 来表征分布）
- ▶ 解码器：从概率分布中采样并还原得到最终输出



$$\text{Loss} = \|\mathbf{x} - \hat{\mathbf{x}}\|^2 + \text{KL}[\mathcal{N}(\mu_x, \sigma_x), \mathcal{N}(0, 1)] = \|\mathbf{x} - D(\mathbf{z})\|^2 + \text{KL}[\mathcal{N}(\mu_x, \sigma_x), \mathcal{N}(0, 1)]$$

$$\text{Loss} = \frac{1}{n} \sum_{i=1}^n [\|\mathbf{x}_i - \hat{\mathbf{x}}_i\|_2^2 + \frac{1}{2} \sum_{i=1}^d (-\ln \sigma^2 + \sigma^2 + \mu^2 - 1)]$$

Source: https://mlserver1.cs.siue.edu/dl_24sp/slides/Lecture-16-VAEs



变分自编码器 (VAE)

重参数化:

- 从 $N(\mu, \sigma)$ 采样得到 z 的过程不可导! 如何优化?
- 可视为在 $N(0, 1)$ 上采样得到一个 ϵ
- 然后计算 $z = \mu + \epsilon \times \sigma$
- 可以计算 z 到 μ 、 σ 的导数

VAE的缺点

- 生成结果与训练过程的输入类似



Source: https://mlserver1.cs.siu.edu/dl_24sp/slides/Lecture-16-VAEs

扩散模型


- ▶ J. Ho, A. Jain, and P. Abbeel. Denoising diffusion probabilistic models[C]. NeurIPS, 2020.
- ▶ DDPM在图像合成方面击败了GAN




扩散模型

基本原理

- 正向扩散过程：不断向输入图像添加高斯噪声




- 反向去噪过程：逐步去噪来恢复原始输入图像



扩散模型

▶ 正向扩散过程



- ▶ 给定输入图像 $\mathbf{x}_0$ ，不断在前一时刻的图像上添加高斯噪声，将输入数据分布转换为近似标准正态分布（即高斯分布），过程固定，无需学习

- ▶ 定义马尔科夫链，在第 t 时间步加噪时，满足以下条件概率

$$q(\mathbf{x}_t|\mathbf{x}_{t-1}) = \mathcal{N}(\mathbf{x}_t; \sqrt{1 - \beta_t}\mathbf{x}_{t-1}, \beta_t\mathbf{I}) \quad \beta_t \in [0, 1]$$

- ▶ 推导出从 $\mathbf{x}_0$ 到 $\mathbf{x}_t$ 的扩散过程


$$q(\mathbf{x}_t|\mathbf{x}_0) = \mathcal{N}(\mathbf{x}_t; \sqrt{\bar{\alpha}_t}\mathbf{x}_0, (1 - \bar{\alpha}_t)\mathbf{I}) \quad \alpha_t = 1 - \beta_t, \bar{\alpha}_t = \prod_{i=1}^T \alpha_i$$

- ▶ 重要性质：可以从 $\mathbf{x}_0$ 采样直接得到任意 $\mathbf{x}_t$

$$\mathbf{x}_t = \sqrt{\bar{\alpha}_t}\mathbf{x}_0 + \sqrt{(1 - \bar{\alpha}_t)}\epsilon, \quad \epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$$

扩散模型

反向去噪过程



- 目标：学习一个神经网络对高斯噪声图像 x_T 逐步去噪，最终还原出图像 x_0

- 初始采样
$$p(x_T) = \mathcal{N}(x_T; \mathbf{0}, \mathbf{I})$$

- 每一步需要学习“从 x_t 恢复 x_{t-1} ”的条件分布，核心在于学习 $\mu_\theta(x_t, t)$ 与 σ_t

$$p_\theta(x_{t-1}|x_t) = \mathcal{N}(x_{t-1}; \mu_\theta(x_t, t), \sigma_t^2 \mathbf{I})$$

- 如果能从 x_t 和 t 预测出正向过程的噪声 $\epsilon_\theta(x_t, t)$ ，就能计算出 x_{t-1}

$$x_{t-1} = \frac{1}{\sqrt{\alpha_t}} \left(x_t - \frac{1 - \alpha_t}{\sqrt{1 - \bar{\alpha}_t}} \epsilon_\theta(x_t, t) \right) + \sigma_t z \quad z \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$$

扩散模型

► 训练的过程 = 训练噪声预测器


► 网络直接预测噪声的原因

► 训练的数据 (**对一次训练**)

► **输入**: 时刻 t 和 图像 $t+1$

► 输出: 预测噪声


► **真值**: t 时刻对应噪声



扩散模型

▶ 噪声预测网络

- ▶ 目的：在反向过程的每一步预测合理的去噪参数
- ▶ 具体结构：改进的U-Net
 - ▶ 时间 t 编码为向量，作为网络的条件输入，来为不同的时间步预测噪声
 - ▶ 将每个尺度的卷积块替换为残差块，并增加自注意力层来增强关系感知能力



扩散模型


▶ 噪声预测网络

▶ 原始U-Net

- ▶ 完全对称的全卷积网络，由编码器和解码器组成
- ▶ 编码器通过一系列下采样，去除输入图像中的冗余信息，并压缩转换到小尺寸的特征图
- ▶ 解码器通过对称的上采样（转置卷积），将图像特征还原到原图尺寸

▶ 改进U-Net

- ▶ 将每个尺度的卷积块替换为残差块，并增加自注意力层来增强关系感知能力
- ▶ 时间 t 编码为向量，作为网络的条件输入，来为不同的时间步预测噪声



Ronneberger O, Fischer P, and Brox T. U-Net: Convolutional networks for biomedical image segmentation. MICCAI, 2015

扩散模型

▶ 训练过程

- ▶ 红框部分，实际就是 x_t

算法 3.1 训练过程^[99]

```
1: repeat
2:    $\mathbf{x}_0 \sim q(\mathbf{x}_0)$ 
3:    $t \sim \mathcal{U}(1, T)$ 
4:    $\epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 
5:   进行梯度下降  $\nabla_{\theta} \|\epsilon - \epsilon_{\theta}(\sqrt{\bar{\alpha}_t}\mathbf{x}_0 + \sqrt{1 - \bar{\alpha}_t}\epsilon, t)\|^2$ 
6: until 收敛
```


▶ 推理过程

算法 3.2 采样过程^[99]

```
1:  $\mathbf{x}_T \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 
2: for  $t = T, \dots, 1$  do
3:    $\mathbf{z} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$  如果  $t > 1$ , 否则  $\mathbf{z} = \mathbf{0}$ 
4:    $\mathbf{x}_{t-1} = \frac{1}{\sqrt{\alpha_t}} \left( \mathbf{x}_t - \frac{1 - \alpha_t}{\sqrt{1 - \bar{\alpha}_t}} \epsilon_{\theta}(\mathbf{x}_t, t) \right) + \sigma_t \mathbf{z}$ 
5: end for
6: return  $\mathbf{x}_0$ 
```


扩散模型

- ▶ One more thing!
 - ▶ 文本信息怎么办?
 - ▶ 作为条件，添加在每一次去噪过程中
 - ▶ 应用：text2image



Stable Diffusion


- ▶ R Rombach, A Blattmann, D Lorenz, P Esser, B Ommer, High-Resolution Image Synthesis with Latent Diffusion Models, CVPR'2022.
- ▶ 训练和推理的扩散和逆扩散过程都在**隐空间**中进行，大大减小了显存使用量和计算量



Stable Diffusion

训练


- 损失函数
$$L_{LDM} := \mathbb{E}_{\mathcal{E}(x), y, \epsilon \sim \mathcal{N}(0,1), t} \left[\|\epsilon - \epsilon_{\theta}(z_t, t, \tau_{\theta}(y))\|_2^2 \right]$$
- 1、给一张图像 x ，经过**自编码器**得到隐空间表示 z_0
- 2、经过随机时间步 t 的加噪 ϵ ，得到 z_t
- 3、将 z_t 输入到U-Net模型，得到预测噪声 $\hat{\epsilon}$ ，反向传播更新模型参数，使预测噪声 $\hat{\epsilon}$ 更接近真实噪声 ϵ



Stable Diffusion


推理

- 给一个随机噪声 z_T ，“减去”U-Net模型预测的噪声 $\hat{\epsilon}$ ，不断去噪得到不带噪声的 z_0 ，再经过解码器得到真实图像 x




Stable Diffusion

- ▶ R Rombach, A Blattmann, D Lorenz, P Esser, B Ommer, High-Resolution Image Synthesis with Latent Diffusion Models, CVPR'2022.




ControlNet

- ▶ ControlNet允许用户通过额外的条件输入（如边缘图、深度图、涂鸦、语义分割图等）来引导图像生成
- ▶ 原始Stable Diffusion对于每一种多模态输入控制条件，都需要在庞大的数据集上更新全部模型参数
- ▶ 核心思想：在不破坏原始扩散模型能力的前提下，注入可控条件，对大型扩散模型的权重进行克隆，并划分为“可训练副本”和“锁定副本”，通过旁路微调可训练副本来实现特定输入的控制



ControlNet

- ▶ L Zhang, A Rao, M Agrawala, Adding conditional control to text-to-image diffusion models, ICCV2023.



Input Canny edge




Default



“masterpiece of fairy tale, giant deer, golden antlers”



“..., quaint city Galic”




Input human pose



Default




“chef in kitchen”



“Lincoln statue”


DiT (Diffusion Transformer)

- ▶ 使用Transformer架构替代U-Net网络，进行噪声预测
- ▶ 输入图像经自编码器压缩到低维latent后，经过patch化输入到级联的DiT中
- ▶ 条件（类别）和时间经过向量化后，为latent中每个像素点提供控制信息



SORA

- 视频压缩网络+diffusion Transformer
 - 支持不同分辨率的提示图/视频输入，生成不同分辨率、长宽比的视频
 - 文字提示准确性和整体生成质量提升，生成视频达到了影视级
 - 生成的视频主体能保持较长时间的时序一致性，生成视频最大时长达到60s




SORA

- 短视频
- 电影
- 游戏
- 机器人
- 教育
- 建筑
- 艺术创作
-




视觉模型的发展

从单模态到多模态的视觉模型




多模态大模型的发展



视觉-语言模型


- ▶ VLM所面临的挑战
 - ▶ 模型不具备迁移能力
 - ▶ 数据的获取
- ▶ NLP领域带来的启发
 - ▶ BERT：自监督训练
 - ▶ GPT：通过prompt赋予模型迁移能力



CLIP

Contrastive Language–Image Pre-training

- ▶ 利用互联网获取的大规模的图像-文本对数据进行预训练，降低对精确人工标注数据的依赖
- ▶ 通过**自监督对比学习**，捕捉图像和文本之间的关联关系，具有多模态理解能力



- ▶ CLIP在计算机视觉的多种下游任务上都表现出强大的泛化能力和零样本学习能力，甚至可以超过监督训练模型的效果


RADFORD A, KIM J W, HALLACY C, et al. Learning transferable visual models from natural language supervision, ICML 2021.

CLIP

CLIP训练

- ▶ 数据收集：4亿图片-文本对
- ▶ 网络结构：双编码器结构
- ▶ 训练范式：对比学习

(1) Contrastive pre-training




N为batch size

CLIP


CLIP推理

- 提取预测类别文本：分类标签 → 文本
- 零样本预测流程
- 与传统分类模型区别

(2) Create dataset classifier from label text




(3) Use for zero-shot prediction



BLIP

- ▶ 提出统一视觉-语言**理解**和**生成**任务的多模态混合编码器-解码器
 - ▶ 1) 单模态编码器：图像-文本对比 (ITC) 损失
 - ▶ 2) 基于图像的文本编码器：文本-图像匹配 (ITM) 损失，提升视觉语言特征融合能力
 - ▶ 3) 基于图像的文本解码器：语言建模 (LM) 损失，使模型具有生成文本的能力




- ▶ 创新点：提出描述生成过滤方法，提高文本描述的质量，提升模型训练效果

BLIP

▶ BLIP描述生成过滤方法

- ▶ Captioner: 用于生成给定图像的描述文本, 使用LM损失进行微调
- ▶ Filter: 用于去除不匹配的图像-文本对, 使用 ITC 和 ITM 损失进行微调



BLIP

▶ BLIP描述生成过滤方法的效果



T_w : "from bridge near my house"

T_s : "a flock of birds flying over a lake at sunset"



T_w : "in front of a house door in Reichenfels, Austria"

T_s : "a potted plant sitting on top of a pile of rocks"



T_w : "the current castle was built in 1180, replacing a 9th century wooden castle"


T_s : "a large building with a lot of windows on it"

▶ BLIP训练流程

- ▶ 用含噪声的网络数据预训练BLIP
- ▶ 在COCO数据集上微调Captioner和Filter
- ▶ 使用Captioner和Filter，对含噪声的网络数据进行清洗
- ▶ 使用清洗后的数据重新训练模型

BLIP-2

- ▶ 问题：多模态对齐难，训练成本高
- ▶ BLIP-2：冻结预训练好的视觉编码器和LLM，只训练轻量Q-Former，降低训练成本




- ▶ 可用于视觉问答、图像描述等

LI J, LI D, SAVARESE S, et al. BLIP-2: Bootstrapping language-image pre-training with frozen image encoders and large language models. arXiv preprint arXiv:2301.12597


BLIP-2

► Q-Former训练

- 第一阶段，类似BLIP，冻结图像编码器（ViT），训练Q-Former，学习与文本最相关的视觉表征



- 第二阶段，用冻结的LLM引导视觉到语言的生成学习，实现zero-shot图像到文本的生成



什么是智能体

- ▶ 智能体：在特定环境中自主感知、决策并执行动作以实现目标的实体



自动驾驶系统



围棋AI




聊天AI



游戏AI



语音助手



机器人

什么是智能体


▶ 智能体两个关键：

▶ “智能”系统

- ▶ 以智能技术/算法为核心的主体
- ▶ 专家符号系统？ 强化学习策略？ LLM/MLLM

▶ 与“环境”交互


- ▶ 通过观测和动作
- ▶ 物理环境：自动驾驶汽车，机器人
- ▶ 虚拟环境：语音助手，Dota，AlphaGo
- ▶ “人”作为环境：ChatGPT



基于大模型的智能体系统

▶ 智能体系统（AI agents）

- ▶ LLM 充当智能体的大脑，将复杂任务分解，并在每个子步骤实现自主决策，处理更加复杂的行动决策任务
- ▶ 除LLM，智能体系统通常还包括规划（planning）、记忆（memory）和工具使用（tool use）模块



<https://lilianweng.github.io/posts/2023-06-23-agent/>

基于大模型的智能体系统

- ▶ 规划 (planning) : 包括子任务分解和反思
 - ▶ 子任务分解 (task decomposition)
 - ▶ 智能体利用 LLM 将大型任务分解为更小、可管理的子任务, 从而高效处理复杂的任务
 - ▶ 常用方法: 思维链 (Chain-of-Thought, CoT)、思维树 (Tree of Thoughts) 等

Chain-of-Thought Prompting

Model Input


Q: Roger has 5 tennis balls. He buys 2 more cans of tennis balls. Each can has 3 tennis balls. How many tennis balls does he have now?

A: Roger started with 5 balls. 2 cans of 3 tennis balls each is 6 tennis balls. $5 + 6 = 11$. The answer is 11.

Q: The cafeteria had 23 apples. If they used 20 to make lunch and bought 6 more, how many apples do they have?



Model Output

A: The cafeteria had 23 apples originally. They used 20 to make lunch. So they had $23 - 20 = 3$. They bought 6 more apples, so they have $3 + 6 = 9$. The answer is 9. ✓



基于大模型的智能体系统

- ▶ 规划 (planning) : 包括子任务分解和反思
 - ▶ 子任务分解 (task decomposition)
 - ▶ 反思 (self-reflection)
 - ▶ 智能体通过完善过去的行动决策和纠正以前的错误来迭代改进
 - ▶ 常用方法: ReAct、Reflexion 和 Chain of Hindsight 等



YAO S, ZHAO J, YU D, et al. ReAct: Synergizing reasoning and acting in language models. ArXiv, 2022, abs/2210.03629

基于大模型的智能体系统


▸ 记忆 (memory)

记忆分类	人类	智能体系统
感知记忆	个体对外部世界的感觉信息的短期存储和处理，包括图像记忆（视觉）、回声记忆（听觉）和触摸记忆（触感），通常持续几秒钟	原始输入（包括文本、图像或其他模态）的嵌入表示。例如，视觉编码器/语音编码器
短期记忆 或 工作记忆	储存着执行当前复杂任务所需要的信息，短时间内活跃、随时可用的少量信息，持续时间为20-30秒	上下文学习的输入。 由于大模型的输入上下文窗口长度是有限的，短期记忆是短暂且有限的。例如，提示工程
长期记忆	将信息存储很长时间，从几天到几十年不等，其存储容量基本上是无限的	作为外部向量存储，智能体可以通过查询和检索利用其中的知识。例如，检索增强生成 (RAG)

基于大模型的智能体系统

► 工具使用 (tool use)

- 通过给LLM配备外部工具大幅扩展模型的能力，如OpenAI为ChatGPT提供了插件和API函数调用功能
- 代表性工作：HuggingGPT，使用ChatGPT作为任务规划器，根据模型描述选择HuggingFace平台中可用的模型，并根据执行结果归纳总结做出响应



SHEN Y, SONG K, TAN X, et al. HuggingGPT: Solving ai tasks with chatgpt and its friends in hugging face. arXiv, 2023, abs/2303.17580.

基于大模型的智能体系统

▶ 动作 (Action)

- ▶ 智能体在具体环境（现实世界或虚拟世界）中执行动作以影响环境的能力至关重要，例如控制物理机器人或设备
- ▶ 规划模块接受工具使用得到的反馈+记忆检索的上下文并综合推理生成动作序列，并执行动作与环境进行交互




Figure 5: Typology of the action module.


LLM智能体框架

- ▶ 大模型智能体框架的关键能力 VS. LLM:
 - ▶ 语言能力：LLM理解和生成语言的能力确保了交互等基本能力
 - ▶ -> 输入输出能力，推理能力，上下文学习能力等
 - ▶ 决策能力：通过规划决策以解决复杂的问题
 - ▶ -> 解决复杂任务的能力
 - ▶ 灵活性：推理、记忆和工具使用确保LLM智能体可以适应各种应用
 - ▶ -> 泛化性

	LLM
	LLM + Planning
	LLM + Planning + Memory
	Agents (LLM + Planning + Memory + Tools)

Manus

- ▶ 首个通用AI智能体，不仅生成想法或协助完成任务，还可以自主执行任务




Manus

▶ 处理各种任务，从自动化工作流程到执行复杂的决策流程，而无需持续的人工干预



▶ 特点

- ▶ 自主执行任务
- ▶ 多模态能力
- ▶ 高级工具调用
- ▶ 自适应学习和优化



MCP (Model Context Protocol)


- ▶ 问题：M个AI应用 & N个工具/系统 → MxN个不同的集成，“重复造轮子”
- ▶ MCP提供了AI应用（聊天机器人、智能体）连接外部工具、数据源和系统的标准，类似USB-C端口
- ▶ MCP提供通用API转换为M+N问题



MCP


▶ MCP 客户端-服务器架构

- ▶ Hosts: AI应用
- ▶ Clients: 管理与一个特定MCP服务器的连接
- ▶ Servers: 通过标准API向AI应用开放工具、资源和提示



A2A (Agent2Agent) 协议

- ▶ 问题：Agent“碎片化”，难以有效协同
- ▶ A2A定义了一套标准的通信规范和互操作框架，使得由不同供应商开发、基于不同技术栈构建的 AI Agent 能够相互发现、安全地交换信息、协调行动并协同完成任务



A2A协议

▶ 关键功能

- ▶ 能力发现：JSON格式的Agent Card展示能力
 - ▶ 任务管理：客户端智能体和远程智能体之间的交流以完成任务为核心，目的是满足用户需求
 - ▶ 协作与通信：智能体之间可以互相发送消息，分享上下文、回复、产物或用户指令。
 - ▶ 用户体验协商：支持超文本交互
-
- ▶ A2A关注智能体间的通信，“找到合适的伙伴一起做事”
 - ▶ MCP关注智能体与环境的交互，具备“做事的能力”



谢谢大家!