

Support Vector Machines

Yongmei Tan
ymtan@bupt.edu.cn

小故事：统计学习理论之父弗拉基米尔·瓦普尼克

弗拉基米尔·瓦普尼克 (Vladimir N. Vapnik, 1936—) 是杰出的数学家、统计学家、计算机科学家。他出生于苏联, 1958 年在乌兹别克国立大学获数学硕士学位, 1964 年在莫斯科控制科学学院获统计学博士学位, 此后一直在该校工作并担任计算机系主任。1990 年(苏联解体的前一年)他离开苏联来到新泽西州的美国电话电报公司贝尔实验室工作, 1995 年发表了最初的 SVM 文章。当时神经网络正当红, 因此这篇文章被权威期刊 *Machine Learning* 要求以“支持向量网络”的名义发表。




实际上, 瓦普尼克在 1963 年就已提出了支持向量的概念, 1968 年他与另一位苏联数学家 A. Chervonenkis 提出了以他们两人的姓氏命名的“VC 维”, 1974 年又提出了结构风险最小化原则, 使得统计学习理论在二十世纪七十年代就已成型。但这些工作主要是以俄文发表的, 直到瓦普尼克随着东欧剧变和苏联解体导致的苏联科学家移民潮来到美国, 这方面的研究才在西方学术界引起重视, 统计学习理论、支持向量机、核方法在二十世纪末大红大紫。

瓦普尼克 2002 年离开美国电话电报公司加入普林斯顿的 NEC 实验室, 2014 年加盟脸书(Facebook)公司人工智能实验室。1995 年之后他还在伦敦大学、哥伦比亚大学等校任教授。据说瓦普尼克在苏联根据一本字典自学了英语及其发音。他有一句名言被广为传诵: “*Nothing is more practical than a good theory.*”

What is a good Decision Boundary?


- Consider a binary classification task with $y = \pm 1$ labels.
- When the training examples are linearly separable, we can set the parameters of a linear classifier so that all the training examples are classified correctly.
- Many decision boundaries!
 - Generative classifiers
 - Logistic regressions ...
- Are all decision boundaries equally good?

Linear Classifiers




$$f(\mathbf{x}, \mathbf{w}, b) = \text{sign}(\mathbf{w} \cdot \mathbf{x} + b)$$

- denotes +1
- denotes -1




How would you classify this data?

Linear Classifiers




- denotes +1
- denotes -1



$$f(\mathbf{x}, \mathbf{w}, b) = \text{sign}(\mathbf{w} \cdot \mathbf{x} + b)$$


How would you classify this data?

Linear Classifiers




$$f(\mathbf{x}, \mathbf{w}, b) = \text{sign}(\mathbf{w} \cdot \mathbf{x} + b)$$

- denotes +1
- denotes -1




How would you classify this data?

Linear Classifiers




- denotes +1
- denotes -1




$$f(\mathbf{x}, \mathbf{w}, b) = \text{sign}(\mathbf{w} \cdot \mathbf{x} + b)$$

How would you classify this data?

Linear Classifiers



- denotes +1
- denotes -1




$$f(\mathbf{x}, \mathbf{w}, b) = \text{sign}(\mathbf{w} \cdot \mathbf{x} + b)$$

Any of these
would be fine..


..but which is
best?

Classifier Margin




$$f(\mathbf{x}, \mathbf{w}, b) = \text{sign}(\mathbf{w} \cdot \mathbf{x} + b)$$

- denotes +1
- denotes -1




Define the **margin** of a linear classifier as the width that the boundary could be increased by before hitting a datapoint.

Maximum Margin



- denotes +1
- denotes -1



$$f(\mathbf{x}, \mathbf{w}, b) = \text{sign}(\mathbf{w} \cdot \mathbf{x} + b)$$

The **maximum margin linear classifier** is the linear classifier with the maximum margin.

This is the simplest kind of SVM (Called an LSVM)

Linear SVM

- 统计学习理论给出了线性分类器边缘与其泛化误差之间的形式化解释, 即结构风险最小化(structural risk minimization)理论

结构风险最小化 (structural risk minimization, SRM) 理论。该理论根据分类器的训练误差 R_e 、训练样本数 N 和模型的复杂度 h (即它的能力 (capacity)), 给出了分类器的泛化误差的一个上界 R 。具体地说, 在概率 $1-\eta$ 下, 分类器的泛化误差在最坏情况下满足

$$R \leq R_e + \varphi\left(\frac{h}{N}, \frac{\log(\eta)}{N}\right)$$


其中, φ 是能力 h 的单调增函数。

一个线性分类器的决策边界可以写成如下形式：

$$\mathbf{w} \cdot \mathbf{x} + b = 0 \quad (5-28)$$

其中， $\mathbf{w}$ 和 b 是模型的参数。

图 显示了包含圆圈和方块的二维训练集。图中的实线表示决策边界，它将训练样本一分为二，划入各自的类中。任何位于决策边界上的样本都必须满足公式 (5-28)。



SVM 的决策边界和边缘

对于任何位于决策边界上方的方块 x_s ，我们可以证明：


$$w \cdot x_s + b = k \quad (5-29)$$

其中 $k > 0$ 。同理，对于任何位于决策边界下方的圆圈 x_c ，我们可以证明：

$$w \cdot x_c + b = k' \quad (5-30)$$

其中 $k' < 0$ 。如果标记所有的方块的类标号为+1，标记所有的圆圈的类标号为-1，则可以用以下的方式预测任何测试样本 z 的类标号 y ：

$$y = \begin{cases} 1 & \text{如果 } w \cdot z + b > 0 \\ -1 & \text{如果 } w \cdot z + b < 0 \end{cases} \quad (5-31)$$



SVM 的决策边界和边缘

Maximum Margin

- Functional margin

对于给定的训练集 T 和超平面 (w,b) , 定义的超平面 (w,b) 关于样本点 (x_i, y_i) 的函数间隔为

$$\hat{\gamma}_i = y_i(w \cdot x_i + b)$$

定义的超平面 (w,b) 关于训练集 T 的函数间隔为超平面 (w,b) 关于 T 中所有的样本点 (x_i, y_i) 的函数间隔为最小值

$$\hat{\gamma} = \min_{i=1, \dots, N} \hat{\gamma}_i$$

函数间隔可以表示分类预测的正确性及确信度。

Maximum Margin

- Geometry margin

对于给定的训练集 T 和超平面 (w, b) , 定义超平面 (w, b) 关于样本点 (x_i, y_i) 的几何间隔为

$$\gamma_i = y_i \left(\frac{w}{\|w\|} \cdot x_i + \frac{b}{\|w\|} \right)$$

定义的超平面 (w, b) 关于训练集 T 的几何间隔为超平面 (w, b) 关于 T 中所有的样本点 (x_i, y_i) 的几何间隔为最小值

$$\gamma = \min_{i=1, \dots, N} \gamma_i$$

超平面 (w, b) 关于样本点 (x_i, y_i) 的几何间隔一般是实例点到超平面的带符号距离, 当样本点被超平面正确分类时就是实例点到超平面的距离。

Maximum Margin


图给出了超平面 (w, b) 及其法向量 w ，点A表示实例 x_i ，其标记为 $y_i = +1$ ，点A与超平面 (w, b) 的距离由线段AB给出，记作

$$\gamma_i = \frac{w}{\|w\|} \cdot x_i + \frac{b}{\|w\|}$$

$\|w\|$ 为 w 的L2范数。

如果点A在超平面的另一侧，那么点A与超平面的距离为

$$\gamma_i = -\left(\frac{w}{\|w\|} \cdot x_i + \frac{b}{\|w\|} \right)$$



如果样本点 (x_i, y_i) 被超平面 (w, b) 正确分类时，点 x_i 与超平面 (w, b) 的距离为

$$\gamma_i = y_i \left(\frac{w}{\|w\|} \cdot x_i + \frac{b}{\|w\|} \right)$$

Maximum Margin

- Function margin and geometry margin

$$\gamma_i = \frac{\hat{y}_i}{\|w\|}$$

$$\gamma = \frac{\hat{y}}{\|w\|}$$

如果 $\|w\|=1$ ，那么函数间隔和几何间隔相等。

如果超平面参数 w 和 b 成比例改变，函数间隔也按此比例改变，而几何间隔不变。

Maximum Margin


- Which one is better?

$$\max_{w,b} \gamma$$

$$\text{s.t.} \quad y_i \left(\frac{w}{\|w\|} \cdot x_i + \frac{b}{\|w\|} \right) \geq \gamma, \quad i = 1, 2, \dots, N$$

最大化超平面 (w,b) 关于训练集的几何间隔 γ

超平面 (w,b) 关于每个训练样本点的几何间隔至少是 γ



Maximum Margin

Function margin

$$\max_{w,b} \quad \frac{\hat{\gamma}}{\|w\|}$$

$$\text{s.t.} \quad y_i(w \cdot x_i + b) \geq \hat{\gamma}, \quad i=1,2,\dots,N$$


取 $\hat{\gamma}=1$

$$\max \frac{1}{\|w\|}$$

$$\text{s.t.} \quad y_i(w \cdot x_i + b) \geq 1, i = 1, 2, \dots, N$$

$$\min_{w,b} \quad \frac{1}{2} \|w\|^2$$

$$\text{s.t.} \quad y_i(w \cdot x_i + b) - 1 \geq 0, \quad i=1,2,\dots,N$$



Maximum Margin

例7.1 正实例点 $x_1=(3,3)^T, x_2=(4,3)^T$, 负实例点 $x_3=(1,1)^T$
，试求最大间隔分割平面

$$f(x)=\text{sign}(w \cdot x + b), w=(w_1, w_2)^T, x=(x^{(1)}, x^{(2)})^T.$$

Maximum Margin

- 凸二次规划问题(Convex quadratic programming)

$$\min_w f(w)$$

$$\text{s.t. } g_i(w) \leq 0, \quad i=1,2,\dots,k$$

$$h_i(w) = 0, \quad i=1,2,\dots,l$$

目标函数 $f(w)$ 和约束函数 $g_i(w)$ 都是 R^n 上连续可微的凸函数, 约束函数 $h_i(w)$ 是 R^n 上的仿射函数。

目标函数 $f(w)$ 是二次函数且约束函数 $g_i(w)$ 是放射函数, 上述凸最优化问题成为凸二次规划问题。

Maximum Margin

- 线性可分支持向量机的学习算法

(1) 求解约束最优化问题:

$$\min_{w,b} \frac{1}{2} \|w\|^2$$

$$\text{s.t. } y_i(w \cdot x_i + b) - 1 \geq 0, \quad i = 1, 2, \dots, N$$

(2) 根据步骤(1)中求解得到的参数得到最优分离超平面:

$$w^* \cdot x + b^* = 0$$

以及分类决策函数:

$$f(x) = \text{sign}(w^* \cdot x + b^*)$$

Maximum Margin

- 学习的拉格朗日对偶算法

为训练数据集中每一个实例引入拉格朗日系数 (lagrange multiplier) 构造拉格朗日函数:

$$L(w, b, \alpha) = \frac{1}{2} (w \cdot w) - \sum_{i=1}^n \alpha_i \{y_i [(w \cdot x_i) + b] - 1\}$$

其中, $\alpha_i \geq 0, i = 1, 2, \dots, N$, $\alpha = (\alpha_1, \alpha_2, \dots, \alpha_N)^T$ 为拉格朗日乘子向量。

Maximum Margin

经过整理可得：

$$L(w, b, \alpha) = \frac{1}{2} \|w\|^2 - \sum_{i=1}^N \alpha_i y_i (w \cdot x_i + b) + \sum_{i=1}^N \alpha_i$$

根据拉格朗日对偶性，可以将原始问题转换为对偶问题：

$$\max_{\alpha} \min_{w, b} L(w, b, \alpha)$$

Maximum Margin

为了最小化拉格朗日函数, 先对拉格朗日函数 L 关于 w 和 b 求偏导, 并令其为0:

$$\nabla_w L(w, b, \alpha) = w - \sum_{i=1}^N \alpha_i y_i x_i = 0$$

$$\nabla_b L(w, b, \alpha) = \sum_{i=1}^N \alpha_i y_i = 0$$

Maximum Margin

可得：

$$w = \sum_{i=1}^N \alpha_i y_i x_i$$

$$\sum_{i=1}^N \alpha_i y_i = 0$$

将上述结果带入拉格朗日函数，可以将拉格朗日函数变换为仅包含拉格朗日乘子的函数，以简化最优化问题。

$$L(w, b, \alpha) = \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1, j=1}^N y_i y_j \alpha_i \alpha_j x_i x_j - b \sum_{i=1}^N \alpha_i y_i$$

Maximum Margin

上式中的最后一项值为0, 因此最终可得:

$$\min_{w,b} L(w, b, \alpha) = -\frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) + \sum_{i=1}^N \alpha_i$$

然后需要求 $\min_{w,b} L(w, b, \alpha)$ 对 α 的极大:

$$\max_{\alpha} -\frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) + \sum_{i=1}^N \alpha_i$$

$$\text{s. t. } \sum_{i=1}^N \alpha_i y_i = 0$$

$$\alpha_i \geq 0, i = 1, 2, \dots, N$$

Maximum Margin

w^* , a^* 分别是原始问题和对偶问题的解的充要条件是
 w^* , a^* 满足以下Karush-Kuhn-Tucker (KKT) 条件:

$$\nabla_w L(w^*, b^*, \alpha^*) = w^* - \sum_{i=1}^N \alpha_i^* y_i x_i = 0$$

$$\nabla_b L(w^*, b^*, \alpha^*) = - \sum_{i=1}^N \alpha_i^* y_i = 0$$

$$\begin{aligned} \alpha_i^* (y_i (w^* \cdot x_i + b^*) - 1) &= 0, & i &= 1, 2, \dots, N \\ y_i (w^* \cdot x_i + b^*) - 1 &\geq 0, & i &= 1, 2, \dots, N \\ \alpha_i^* &\geq 0, & i &= 1, 2, \dots, N \end{aligned}$$

Maximum Margin

令对偶最优化问题对 a 的解为：

$$\alpha^* = (\alpha_1^*, \alpha_2^*, \dots, \alpha_N^*)^T$$

可以通过由 a^* 求得原始问题对 w^* 与 b^* 的解。

对上述满足KKT等式的条件进行整理可得：

$$w^* = \sum_{i=1}^N \alpha_i^* y_i x_i$$

定理： 设 $\alpha^* = (\alpha_1^*, \alpha_2^*, \dots, \alpha_i^*)^T$ 是对偶最优问题的解

则存在下标 j , 使得 $\alpha_j^* > 0$, 并可按下式求得原始问题的解。

证明： 由 $w^* = \sum_i \alpha_i^* y_i x_i$ 其中至少有一个 $\alpha_j^* > 0$

反证法：

假设 $\alpha^* = 0$ 由 $\nabla_w L(w^*, b^*, \alpha^*) = w^* - \sum_{i=1}^N \alpha_i^* y_i x_i = 0$ 可知 $w^* = 0$, $y_j (w^* \cdot x_j + b^*) - 1 = 0$

但这不是原始优化问题的解, 产生矛盾

将 $w^* = \sum_i \alpha_i^* y_i x_i$ 代入式 $y_j (w^* \cdot x_j + b^*) - 1 = 0$ 并注意到 $y_j^2 = 1$

$$b^* = y_j - \sum_{i=1}^N \alpha_i^* y_i (x_i \cdot x_j)$$

Maximum Margin

对于 $\alpha_i^* > 0$ 的实例

$$y_i(w^* \cdot x_i + b^*) - 1 = 0$$

b^* 是对于一个实例进行分类的值, 由上式可以看出, 在 w^* 已知的情况下, 可以将任意一个支持向量代入上式中进行求解, 即:

$$b^* = y_i - \sum_{i=1}^N \alpha_i^* y_i (x_i \cdot x_j)$$

其中 (x_i, y_i) 为选择的一个支持向量。

Maximum Margin

当 w^* 与 b^* 均已知, 便得到了最优分离超平面

$$\sum_{i=1}^N \alpha_i^* y_i (x \cdot x_i) + b^* = 0$$

最终得到的最优分类决策函数为:

$$\begin{aligned} f(x) &= \text{sign}\{(w^* \cdot x) + b^*\} \\ &= \text{sign}\left\{\sum_{i=1}^N \alpha_i^* y_i (x_i \cdot x) + b^*\right\} \end{aligned}$$

其中 $\text{sign}()$ 为符号函数, x 为新输入的实例, 通过决策函数 $f(x)$ 可以决定新实例 x 的分类结果。

Maximum Margin

支持向量是训练数据集中全体实例的一小部分。

由Karush-Kuhn-Tucker(KKT)互补条件可知：

$$\alpha_i^*(y_i(w^* \cdot x_i + b^*) - 1) = 0, \quad i = 1, 2, \dots, N$$


对于任意一个 $\alpha_i^* > 0$ 对应的实例 x_i , 必然有

$$y_i(w^* \cdot x_i + b^*) - 1 = 0$$

可以看出, 支持向量 x_i 一定在间隔边界上, 即


$$w^* \cdot x_i + b^* = \pm 1$$

Maximum Margin



- denotes +1
- denotes -1

Support Vectors
are those
datapoints that
the margin
pushes up
against




$$f(\mathbf{x}, \mathbf{w}, b) = \text{sign}(\mathbf{w} \cdot \mathbf{x} + b)$$

The **maximum margin linear classifier** is the linear classifier with the maximum margin.

This is the simplest kind of SVM (Called an LSVM)

Linear SVM



Maximum Margin

例7.2正实例点 $x_1=(3,3)^T, x_2=(4,3)^T$,负实例点 $x_3=(1,1)^T$
，试求最大间隔分割平面


$$f(x)=\text{sign}(w \cdot x + b), w=(w^{(1)}, w^{(2)})^T, x=(x^{(1)}, x^{(2)})^T.$$

This is going to be a problem!

What should we do?

• denotes +1

◦ denotes -1




This is going to be a problem!

What should we do?

Idea 1:

Find minimum $\|w\|$, while minimizing number of training set errors.

- denotes +1
- denotes -1



This is going to be a problem!

What should we do?


Idea 1:

Minimize

$$\mathbf{w} \cdot \mathbf{w} + C (\# \text{train errors})$$

Tradeoff parameter

- denotes +1
- denotes -1



There's a serious practical problem that's about to make us reject this approach.

This is going to be a problem!


What should we do?

Idea 2:

Minimize

$\mathbf{w} \cdot \mathbf{w} + C$ (*distance of error points to their correct place*)

- denotes +1
- denotes -1



Support Vector Machine (SVM) for Noisy Data

$$\{\vec{w}^*, b^*\} = \min_{\vec{w}, b} \sum_{i=1}^d w_i^2 + c \sum_{j=1}^N \varepsilon_j$$


$$y_1 (\vec{w} \cdot \vec{x}_1 + b) \geq 1 - \varepsilon_1$$

$$y_2 (\vec{w} \cdot \vec{x}_2 + b) \geq 1 - \varepsilon_2$$

...

$$y_N (\vec{w} \cdot \vec{x}_N + b) \geq 1 - \varepsilon_N$$

- Any problem with the above formulism?



Support Vector Machine (SVM) for Noisy Data

$$\{\vec{w}^*, b^*\} = \min_{\vec{w}, b} \sum_{i=1}^d w_i^2 + c \sum_{j=1}^N \varepsilon_j$$


$$y_1 (\vec{w} \cdot \vec{x}_1 + b) \geq 1 - \varepsilon_1, \varepsilon_1 \geq 0$$

$$y_2 (\vec{w} \cdot \vec{x}_2 + b) \geq 1 - \varepsilon_2, \varepsilon_2 \geq 0$$

...

$$y_N (\vec{w} \cdot \vec{x}_N + b) \geq 1 - \varepsilon_N, \varepsilon_N \geq 0$$

- Balance the trade off between margin and classification errors



Support Vector Machine for Noisy Data

$$\{\vec{w}^*, b^*\} = \underset{\vec{w}, b}{\operatorname{argmin}} \sum_i w_i^2 + c \sum_{j=1}^N \varepsilon_j$$

$$\left. \begin{array}{l} y_1 (\vec{w} \cdot \vec{x}_1 + b) \geq 1 - \varepsilon_1, \varepsilon_1 \geq 0 \\ y_2 (\vec{w} \cdot \vec{x}_2 + b) \geq 1 - \varepsilon_2, \varepsilon_2 \geq 0 \\ \dots \\ y_N (\vec{w} \cdot \vec{x}_N + b) \geq 1 - \varepsilon_N, \varepsilon_N \geq 0 \end{array} \right\} \text{inequality constraints}$$

How do we determine the appropriate value for c ?

Support Vector Machine for Noisy Data

得到如下凸二次规划问题(原始问题)

$$\begin{aligned} \min_{w, b, \xi} & \frac{1}{2} w^T w + C \sum_{i=1}^N \xi_i \\ \text{s. t. } & y_i [(w^* \cdot x_i) + b^*] - 1 + \xi_i \geq 0 \\ & \xi_i \geq 0, \quad 0 \leq i \leq N \end{aligned}$$

Support Vector Machine for Noisy Data

- 学习的拉格朗日对偶算法

引入拉格朗日乘子, 得到Lagrangian函数:

$$\begin{aligned} \Psi(w, b, \xi, \alpha, \mu) \\ = \frac{1}{2} \|w\|^2 + C \sum_{i=1}^N \xi_i \\ - \sum_{i=1}^m \alpha_i [y^{(i)}(w^T x^{(i)} + b) - 1 + \xi_i] - \sum_{i=1}^N \mu_i \xi_i \end{aligned}$$

其中 $\alpha_i \geq 0, \mu_i \geq 0$

转换为对偶问题, 即拉格朗日函数的极大极小问题。

Support Vector Machine for Noisy Data

先求 $L(w, b, \varepsilon, \alpha, \mu)$ 对于参数 w, b, ε 的极小:

$$\nabla_w \Psi(w, b, \xi, \alpha, \mu) = w - \sum_{i=1}^N \alpha_i y_i x_i = 0$$

$$\nabla_b \Psi(w, b, \xi, \alpha, \mu) = - \sum_{i=1}^N \alpha_i y_i = 0$$

$$\nabla_{\xi_i} \Psi(w, b, \xi, \alpha, \mu) = C - \alpha_i - \mu_i = 0$$

Support Vector Machine for Noisy Data

整理可得

$$w = \sum_{i=1}^N \alpha_i y_i x_i$$

$$\sum_{i=1}^N \alpha_i y_i = 0$$

$$C - \alpha_i - \mu_i = 0$$

帶入拉格朗日函数：

$$\begin{aligned} & \Psi(w, b, \xi_i, \alpha, \beta) \\ &= \frac{1}{2} w^T w + C \sum_{i=1}^N \xi_i - \sum_{i=1}^m \alpha_i [y_i (w^T x_i + b) + \xi_i - 1] \\ & \quad - \sum_{i=1}^N \mu_i \xi_i \end{aligned}$$

Support Vector Machine for Noisy Data

$$\begin{aligned} &= \frac{1}{2} w^T w + \sum_{i=1}^N (C - \alpha_i - \mu_i) \xi_i - \left(\sum_{i=1}^N \alpha_i y_i x_i^T \right) w \\ &\quad - \left(\sum_{i=1}^N \alpha_i y_i \right) b + \sum_{i=1}^N \alpha_i \end{aligned}$$

Support Vector Machine for Noisy Data

对 $\min_{w,b,\xi} \Psi(w, b, \xi, \alpha, \mu)$ 求 α 的极大, 即得对偶问题:

$$\underset{\alpha}{\text{maximize}} \Psi_D = \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i,j} \alpha_i \alpha_j y_i y_j x_i \cdot x_j$$

其中:

$$0 \leq \alpha_i \leq C$$

$$\sum_i \alpha_i y_i = 0$$

Support Vector Machine for Noisy Data

由KKT条件, 可得

$$w^* = \sum_{i=1}^N \alpha_i^* y_i x_i$$
$$b^* = y_i - \sum_{i=1}^N \alpha_i^* y_i (x_i \cdot x_j)$$

所以最终的分离超平面为

$$\sum_{i=1}^N \alpha_i^* y_i (x_i \cdot x_j) + b^* = 0$$

分类决策函数为

$$f(x) = \text{sign} \left(\sum_{i=1}^N \alpha_i^* y_i (x \cdot x_i) + b^* \right)$$

Thank You!


给定平面 $Ax + By + Cz + D = 0$

求平面外一点 $Q(x_0, y_0, z_0)$ 到平面的距离 d

解：任取平面内一点 $P(x, y, z)$ 连接 PQ ,

过 P 做平面的法向量 $\vec{n} = (A, B, C)$

可知 Q 到平面的距离 d 恰是 PQ 在法向量 $\vec{n}$ 上的投影长度。



$$d = |\overrightarrow{PQ}| \cdot \cos \theta$$

$$= \frac{|\vec{n}|}{|\vec{n}|} \cdot |\overrightarrow{PQ}| \cdot \cos \theta \text{ (乘以 } |\vec{n}| \text{ 再除以 } |\vec{n}| \text{)}$$

$$= \frac{\overrightarrow{PQ} \cdot \vec{n}}{|\vec{n}|} \text{ (等式上边正好是 } \overrightarrow{PQ} \text{ 和 } \vec{n} \text{ 的点积)}$$

$$= \frac{A(x_0 - x) + B(y_0 - y) + C(z_0 - z)}{\sqrt{A^2 + B^2 + C^2}} \text{ (} \overrightarrow{PQ} = (x_0 - x, y_0 - y, z_0 - z) \text{)}$$

$$= \frac{Ax_0 + By_0 + Cz_0 - (Ax + By + Cz)}{\sqrt{A^2 + B^2 + C^2}} \text{ (展开)}$$

$$= \frac{Ax_0 + By_0 + Cz_0 + D}{\sqrt{A^2 + B^2 + C^2}} \text{ (} P \text{ 在平面内所以 } Ax + By + Cz = -D \text{)}$$

$$= \frac{|Ax_0 + By_0 + Cz_0 + D|}{\sqrt{A^2 + B^2 + C^2}} \text{ (为保证结果为正, 在等式上加绝对值)}$$

如果法向量是单位向量的话, 那么分母为1

平面向量的数量积

(1)定义：已知两个非零向量 $\boldsymbol{a}$ 与 $\boldsymbol{b}$ ，它们的夹角为 θ ，则数量 $|\boldsymbol{a}||\boldsymbol{b}|\cos \theta$ 叫作 $\boldsymbol{a}$ 与 $\boldsymbol{b}$ 的数量积(或内积)，记作 $\boldsymbol{a} \cdot \boldsymbol{b}$ ，即 $\boldsymbol{a} \cdot \boldsymbol{b} = \underline{|\boldsymbol{a}||\boldsymbol{b}|\cos \theta}$ ，规定零向量与任一向量的数量积为 0 ，即 $0 \cdot \boldsymbol{a} = 0$.

(2)几何意义：数量积 $\boldsymbol{a} \cdot \boldsymbol{b}$ 等于 $\boldsymbol{a}$ 的长度 $|\boldsymbol{a}|$ 与 $\boldsymbol{b}$ 在 $\boldsymbol{a}$ 的方向上的投影 $|\boldsymbol{b}|\cos \theta$ 的乘积.

平面向量数量积的性质及其坐标表示

设向量 $\mathbf{a}=(x_1, y_1)$, $\mathbf{b}=(x_2, y_2)$, θ 为向量 $\mathbf{a}$, $\mathbf{b}$ 的夹角.

(1)数量积: $\mathbf{a} \cdot \mathbf{b} = |\mathbf{a}| |\mathbf{b}| \cos \theta = x_1 x_2 + y_1 y_2$.

(2)模: $|\mathbf{a}| = \sqrt{\mathbf{a} \cdot \mathbf{a}} = \sqrt{x_1^2 + y_1^2}$.

(3)夹角: $\cos \theta = \frac{\mathbf{a} \cdot \mathbf{b}}{|\mathbf{a}| |\mathbf{b}|} = \frac{x_1 x_2 + y_1 y_2}{\sqrt{x_1^2 + y_1^2} \cdot \sqrt{x_2^2 + y_2^2}}$.

(4) $\mathbf{a} \perp \mathbf{b}$ 的充要条件: $\mathbf{a} \cdot \mathbf{b} = 0 \Leftrightarrow x_1 x_2 + y_1 y_2 = 0$.

(5) $|\mathbf{a} \cdot \mathbf{b}| \leq |\mathbf{a}| |\mathbf{b}|$ (当且仅当 $\mathbf{a} \parallel \mathbf{b}$ 时等号成立) $\Leftrightarrow |x_1 x_2 + y_1 y_2| \leq \sqrt{x_1^2 + y_1^2} \cdot \sqrt{x_2^2 + y_2^2}$.

软间隔分割 α_i 的上限 被替换成了 C ？

$$0 \leq \alpha_i \leq C$$

$$C - \alpha_i - \mu_i = 0$$

$$\alpha_i \geq 0$$

$$\mu_i \geq 0, \quad i = 1, 2, \dots, N$$

$$\Rightarrow C - \alpha_i = \mu_i$$

$$\mu_i \geq 0$$

$$\Rightarrow C - \alpha_i \geq 0$$

$$\Rightarrow C \geq \alpha_i$$