

Expectation Maximization

Yongmei Tan
ymtan@bupt.edu.cn

Model Building with Partial Observations

- Our goal is to build a probabilistic model
 - A model is defined by a set of parameters θ
- The model parameters can be estimated from a set of training examples: $x_1, x_2, \dots, x_n$
 - x_i 's are identically and independently distributed (iid)
- Unfortunately, we only get to observe part of each training example:
 - $x_i = (z_i, y_i)$ and we can only observe y_i .
- How do we build the model?

Example: POS Tagging

- Complete data: A sentence (a sequence of words) and a corresponding sequence of POS tags.
- Observed data: the sentence
- Unobserved data: the sequence of tags
- Model: an HMM with transition/emission probability tables.

- Pierre NNP Vinken NNP , , 61 CD years NNS old JJ , , will MD join VB the DT board NN as IN a DT nonexecutive JJ director NN Nov. NNP 29 CD . .
- Mr. NNP Vinken NNP is VBZ chairman NN of IN Elsevier NNP N.V. NNP , , the DT Dutch NNP publishing VBG group NN . .
- Rudolph NNP Agnew NNP , , 55 CD years NNS old JJ and CC former JJ chairman NN of IN Consolidated NNP Gold NNP Fields NNP PLC NNP , , was VBD named VBN a DT nonexecutive JJ director NN of IN this DT British JJ industrial JJ conglomerate NN . .

$$c(\text{JJ})=7 \quad c(\text{JJ}, \text{NN})=4, \quad P(\text{NN}|\text{JJ})=4/7$$

Example: Parsing

- Complete Data: a sentence and its parse tree.
- Observed data: the sentence
- Unobserved data: the nonterminal categories and their relationships that form the parse tree.
- Model:
 - PCFG or anything that allows one to compute the probability of parse trees.

Example: Semantic Labeling

- Complete Data: (context, cluster, word)
- Observed Data: (context, word)
- Unobserved Data: cluster
- Model:
 - $P(\text{context}, \text{cluster}, \text{word}) = P(\text{context})P(\text{cluster}|\text{context})P(\text{word}|\text{cluster})$

What is the best Model?

- There are many possibly models
 - Many possible ways to set the model parameters.
- We obviously want the “best” model.
- Which model is the best?
 - The model that assigns the highest probability to the observation is the best.
 - Maximize $\prod_i P_{\theta}(y_i)$, or equivalently $\sum_i \log P_{\theta}(y_i)$
 - What about maximizing the probability of the hidden data?
 - This is know as the maximum likelihood estimation (MLE)

MLE Example

- A coin with $P(H)=p$, $P(T)=q$.
 - We observed m H's and n T's.
 - What are p and q according to MLE?
- Maximize $\sum_i \log P_{\theta}(y_i) = \log p^m q^n$
 - Under the constraint: $p+q=1$
- Lagrange Method:
 - Define $g(p,q)=m \log p + n \log q + \lambda(p+q-1)$
 - Solve the equations

$$\frac{\partial g(p,q)}{\partial p} = 0, \quad \frac{\partial g(p,q)}{\partial q} = 0, \quad p + q = 1$$

Example

- Suppose we have two coins. Coin 1 is fair. Coin 2 has probability p generating H.
 - They each have $\frac{1}{2}$ probability to be chosen and tossed.
 - The complete data is $(1, H), (1, T), (2, T), (1, H), (2, T)$
 - We only know the result of the toss, but don't know when coin was chosen.
 - The observed data is H, T, T, H, T.
- Problem:
 - Suppose the observations include m H's and n T's.
 - How to estimate p to maximize $\sum_i \log P_{\theta}(y_i)$?
- Unfortunately, we often cannot find the best θ by solving equations.

Need for Iterative Algorithm

- Example:
 - Three coins, 0, 1, and 2, with probabilities p_0 , p_1 , and p_2 generating H.
 - Experiment: Toss coin 0
 - If H, toss coin 1 three times
 - If T, toss coin 2 three times
 - Observations:
 - $\langle HHH \rangle, \langle TTT \rangle, \langle HHH \rangle, \langle TTT \rangle, \langle HHH \rangle$
 - What is MLE for p_0 , p_1 , and p_2 ?

Overview of EM

- Create an initial model, $\theta^{(0)}$.
 - Arbitrarily, randomly, or with a small set of training examples.
- Use the model $\theta^{(i)}$ to obtain another model θ such that
$$\sum_j \log P_{\theta}(y_j) > \sum_j \log P_{\theta^{(i)}}(y_j)$$
- Repeat the above step until reaching a local maximum.
 - Guaranteed to find a better model after each iteration.

Maximizing Likelihood

- How do we find a better model θ given a model $\theta^{(i)}$?
- Can we use Lagrange method to maximize $\sum_j \log P_{\theta}(y_j)$?
 - If this can be done, there is no need to iterate!

- **EM**算法是一种迭代算法，1977年由**Dempster**等人提出，用于含有隐变量 (**hidden variable**) 的概率模型参数的极大似然估计，或极大后验概率估计。
 - **EM**算法的每次迭代由两步组成
 - **E**步，求期望**expectation**
 - **M**步，求极大**maximization**
- 简称**EM**算法。


基础知识

- 凸函数：在某个向量空间的凸集 C （区间）上实值函数 f ，在其定义域 C 上的任意点 x ， y ，以及 $t \in [0,1]$,有

$$f(t \cdot x + (1-t) \cdot y) \leq t \cdot f(x) + (1-t) \cdot f(y)$$

如果对于任意的有 $t \in (0,1)$, 则函数 f 是严格凸的。

$$f(t \cdot x + (1-t) \cdot y) < t \cdot f(x) + (1-t) \cdot f(y)$$




- 凹函数：凹函数是一个定义在某个向量空间的凹子集 C （区间）上的实值函数 f 。

设 f 为定义在区间 I 上的函数，若对 I 上的任意两点 x ， y 和任意的实数 $t \in [0, 1]$ ，总

$$f(t \cdot x + (1-t) \cdot y) \geq t \cdot f(x) + (1-t) \cdot f(y)$$

则 f 称为 I 上的凹函数。



- 期望：一个离散随机变量的期望是试验中每次可能结果的概率乘以其结果的总和。
- 设 Y 是随机变量 X 的函数， $Y=g(X)$ (g 是连续函数)，则

(1) X 是离散型随机变量，它的分布律为 $P(X=x_k)=p_k, k=1,2,\dots$ ，若

$$\sum_{k=1}^{\infty} g(x_k)p_k \text{ 绝对收敛, 则期望值计算为 } E[Y]=E[g(X)]=\sum_{k=1}^{\infty} g(x_k)p_k。$$

(2) X 是连续型随机变量，存在相应的概率密度函数 $f(x)$ ，若积分

$$\int_{-\infty}^{+\infty} g(x)f(x)dx \text{ 绝对收敛, 则期望值计算为 } E[Y]=E[g(X)]=\int_{-\infty}^{+\infty} g(x)f(x)dx。$$

似然函数与极大似然估计

- 设随机样本 $X_1, X_2, \dots, X_n$ 来自分布密度（或概率函数）为 $f(X, \theta)$ 的总体，其中 θ 是未知参数，则

$$L(\theta; X_1, \dots, X_n) = f(X_1, \theta) \dots f(X_n, \theta)$$

称为样本 $(X_1, X_2, \dots, X_n)$ 的似然函数（likelihood function），简记为 $L(\theta)$ 。

- 使似然函数 $L(\theta)$ 取最大值的 $\hat{\theta}$ ，即

$$L(\hat{\theta}) = \sup_{\theta} L(\theta)$$

称为 θ 的极大似然估计（maximum likelihood estimator, MLE），记之为 $\hat{\theta}_{\text{MLE}}$ ，等价于求 $\hat{\theta}$ 。

似然函数与极大似然估计

- 使 $L(\theta; x_1, \dots, x_n)$ 取最大值的 θ 时，出现样本值 $(x_1, x_2, \dots, x_n)$ 的可能性最大，也就是说，使 $L(\theta; x_1, \dots, x_n)$ 达到最大值的 θ 就是最有可能导致样本值 $(x_1, x_2, \dots, x_n)$ 出现的 θ 值。
- 极大似然估计是在给定模型（含有未知参数）和数据集的情况下，估计出最佳的模型中未知参数的值，这些参数的取值可以使模型实现对给定数据集最大程度的拟合。

Expectation maximization algorithm

EM算法引入

• **例1. (三硬币模型)** 假设有3枚硬币, 分别记作 A, B, C 。这些硬币正面出现的概率分别为 π, p 和 q 。

投币实验如下, 先投 A , 如果 A 是正面, 即 $A=1$, 那么选择投 B ; $A=0$, 投 C 。

最后, 如果 B 或者 C 是正面, 那么 $y=1$; 是反面, 那么 $y=0$;

独立重复 n 次试验 ($n=10$), 观测结果如下: $1, 1, 0, 1, 0, 0, 1, 0, 1, 1$
假设只能观测到投掷硬币的结果, 不能观测投掷硬币的过程。

问如何估计三硬币正面出现的概率, 即 π, p 和 q 的值。

• **解** 三硬币模型可以写作

$$\begin{aligned} P(y|\theta) &= \sum P(y, z|\theta) = \sum P(z|\theta)P(y|z, \theta) \\ &= \pi p^y (1-p)^{1-y} + (1-\pi) q^y (1-q)^{1-y} \end{aligned}$$

随机变量 y 是观测变量，表示一次实验观测的结果是**1**或**0**；

随机变量 z 是隐变量，表示未观测到的掷硬币**A**的结果；

$\theta = (\pi, p, q)$ 是模型参数。

- 将观测数据表示为 $Y = (Y_1, Y_2, Y_3 \cdots Y_n)^T$ ，未观测数据表示为 $Z = (Z_1, Z_2, Z_3 \cdots Z_n)^T$ ，则观测数据的似然函数为

$$P(Y|\theta) = \sum P(Z|\theta)P(Y|Z, \theta)$$

即

$$P(Y|\theta) = \prod_{j=1}^n [\pi p^{y_j} (1-p)^{1-y_j} + (1-\pi) q^{y_j} (1-q)^{1-y_j}]$$

考虑求模型参数 $\theta = (\pi, p, q)$ 的极大似然估计，即

$$\hat{\theta} = \arg \max_{\theta} \log P(Y|\theta)$$

EM算法

- 选取参数的初值，记作 $\theta^{(0)} = (\pi^{(0)}, p^{(0)}, q^{(0)})$,
- 通过下面的步骤迭代计算参数的估计值，直到收敛为止。
 - 第 i 次迭代参数的估计值为 $\theta^{(i)} = (\pi^{(i)}, p^{(i)}, q^{(i)})$ 。
 - 第 $i+1$ 次迭代如下

- **E**步：计算在模型参数 $\pi^{(i)}, p^{(i)}, q^{(i)}$ 下观测数据 y_j 来自掷硬币**B**的概率

$$\mu_j^{(i+1)} = \frac{\pi^{(i)} (p^{(i)})^{y_j} (1-p^{(i)})^{1-y_j}}{\pi^{(i)} (p^{(i)})^{y_j} (1-p^{(i)})^{1-y_j} + (1-\pi^{(i)}) (q^{(i)})^{y_j} (1-q^{(i)})^{1-y_j}}$$
- **M**步：计算模型参数的新估计值

$$\pi^{(i+1)} = \frac{1}{n} \sum_{j=1}^n \mu_j^{(i+1)}$$

$$p^{(i+1)} = \frac{\sum_{j=1}^n \mu_j^{(i+1)} y_j}{\sum_{j=1}^n \mu_j^{(i+1)}}$$

$$q^{(i+1)} = \frac{\sum_{j=1}^n (1-\mu_j^{(i+1)}) y_j}{\sum_{j=1}^n (1-\mu_j^{(i+1)})}$$

- 假设模型参数的初值取为

$$\pi^{(0)} = 0.5, p^{(0)} = 0.5, q^{(0)} = 0.5$$

- E步

$$\text{对 } y_j = 1 \text{ 与 } y_j = 0 \text{ 均有 } \mu_j^{(1)} = 0.5$$

- M步

$$\pi^{(1)} = 0.5, p^{(1)} = 0.6, q^{(1)} = 0.6$$

- E步

$$\mu_j^{(2)} = 0.5, \quad j = 1, 2, \dots, 10$$

- M步

$$\pi^{(2)} = 0.5, p^{(2)} = 0.6, q^{(2)} = 0.6$$

- 模型参数 θ 的极大似然估计：

$$\hat{\pi} = 0.5, \hat{p} = 0.6, \hat{q} = 0.6$$

$\pi = 0.5$ 表示硬币**A**是均匀的。

- 如果取初值 $\pi^{(0)} = 0.4, p^{(0)} = 0.6, q^{(0)} = 0.7$ ，得到的模型参数的极大似然估计是 $\hat{\pi} = 0.4064, \hat{p} = 0.5368, \hat{q} = 0.6432$ 。
- **EM**算法与初值的选择有关，选择不同的初值可能得到不同的参数估计值。

- 用 Y 表示观测随机变量的数据， Z 表示隐随机变量的数据， Y 和 Z 连在一起称为完全数据（complete-data），观测数据 Y 称为不完全数据（incomplete-data）。
- 假设给定观测数据 Y ，其概率分布是 $P(Y|\theta)$ ， θ 是需要估计的模型参数，那么不完全数据 Y 的似然函数是 $P(Y|\theta)$ ，对数似然函数 $L(\theta) = \log P(Y|\theta)$ ；
- 假设 Y 和 Z 的联合概率分布是 $P(Y, Z|\theta)$ ，那么完全数据的对数似然函数是 $\log P(Y, Z|\theta)$ 。

EM算法

输入：观测变量 $\mathbf{Y}$ ，隐变量数据 $\mathbf{Z}$ ，联合分布 $P(\mathbf{Y}, \mathbf{Z}|\theta)$ ，条件分布 $P(\mathbf{Z}|\mathbf{Y}, \theta)$ ；

输出：模型参数 θ 。

(1) 选择参数的初值 $\theta^{(0)}$ ，开始迭代；

(2) **E**步：记 $\theta^{(i)}$ 为第 i 次迭代参数 θ 的估计值，在第 $i+1$ 次迭代的**E**步，计算

$$\begin{aligned} Q(\theta, \theta^{(i)}) &= E_{\mathbf{Z}}[\log P(\mathbf{Y}, \mathbf{Z}|\theta) | \mathbf{Y}, \theta^{(i)}] \\ &= \sum_{\mathbf{Z}} \log P(\mathbf{Y}, \mathbf{Z}|\theta) P(\mathbf{Z}|\mathbf{Y}, \theta^{(i)}) \end{aligned}$$

$P(\mathbf{Z}|\mathbf{Y}, \theta^{(i)})$ 是在给定观测数据 $\mathbf{Y}$ 和当前参数估计 $\theta^{(i)}$ 下隐变量数据 $\mathbf{Z}$ 的条件概率分布；

函数 $Q(\theta, \theta^{(i)})$ 是**EM**算法的核心，称为**Q函数**（**Q function**）。

(3) M步：求使 $Q(\theta, \theta^{(i)})$ 极大化的 θ ，确定第 $i+1$ 次迭代的参数的估计值 $\theta^{(i+1)}$

$$\theta^{i+1} = \underset{\theta}{\operatorname{argmax}} Q(\theta, \theta^{(i)})$$

(4)重复第 (2) 步和第 (3) 步，直到收敛。

- **(Q函数)** 完全数据的对数似然函数 $\log P(Y, Z|\theta)$ 关于在给定观测数据 Y 和当前参数 $\theta^{(i)}$ 下对未观测数据 Z 的条件概率分布 $P(Z|Y, \theta^{(i)})$ 的期望称为**Q函数**，即

$$Q(\theta, \theta^{(i)}) = E_Z[\log P(Y, Z|\theta) | Y, \theta^{(i)}]$$

EM算法的导出

- 一个含有隐变量的概率模型，目标是极大化观测数据（不完全数据） Y 关于参数 θ 的对数似然函数，即极大化

$$\begin{aligned} L(\theta) &= \log P(Y|\theta) = \log \sum_Z P(Y, Z|\theta) \\ &= \log(\sum_Z P(Y|Z, \theta) P(Z|\theta)) \end{aligned}$$

式中有未观测数据并有包含和(或积分)的对数。

- 考虑两者的差

$$L(\theta) - L(\theta^{(i)}) = \log \left(\sum_Z P(Y|Z, \theta) P(Z|\theta) \right) - \log P(Y|\theta^{(i)})$$

凸函数是一个定义在某个向量空间的凸子集 C (区间) 上的实值函数 f , 如果在其定义域 C 上的任意两点 x_1, x_2 , $0 \leq \lambda \leq 1$, 有

$$\lambda f(x_1) + (1 - \lambda)f(x_2) \geq f(\lambda x_1 + (1 - \lambda)x_2) \quad (1)$$

也就是说凸函数任意两点的割线位于函数图形上方, 这也是Jensen不等式的两点形式。

若对于任意点集 $\{x_i\}$, 若 $\lambda_i \geq 0$ 且 $\sum_i \lambda_i = 1$, 使用数学归纳法, 可以证明凸函数 $f(x)$ 满足:

$$f\left(\sum_{i=1}^M \lambda_i x_i\right) \leq \sum_{i=1}^M \lambda_i f(x_i) \quad (2)$$

公式(2)被称为 Jensen 不等式, 它是式(1)的泛化形式。

在概率论中, 如果把 λ_i 看成取值为 x_i 的离散变量 x 的概率分布, 那么公式(2)就可以写成

$$f(E[x]) \leq E[f(x)]$$

其中, $E[\cdot]$ 表示期望。

Jensen's Inequality

- The proof used the inequality

$$\begin{aligned} \log \left(\sum_Z P(Z|Y, \theta^{(i)}) \frac{P(Y|Z, \theta)P(Z|\theta)}{P(Z|Y, \theta^{(i)})} \right) \\ \geq \sum_Z P(Z|Y, \theta^{(i)}) \log \frac{P(Y|Z, \theta)P(Z|\theta)}{P(Z|Y, \theta^{(i)})} \end{aligned}$$

$$\log(\sum_j \lambda_j y_j) \geq \sum_j \lambda_j \log(y_j) \text{ 其中 } \lambda_j \geq 0 \sum_j \lambda_j = 1$$

- Even more generally, if f is a convex function,
 $E[f(x)] \geq f(E[x])$
 - Jensen's Inequality

- 利用**Jensen**不等式 (**Jensen inequality**) 得到其下界:

$$\begin{aligned}
 L(\theta) - L(\theta^{(i)}) &= \log \left(\sum_Z P(Z|Y, \theta^{(i)}) \frac{P(Y|Z, \theta)P(Z|\theta)}{P(Z|Y, \theta^{(i)})} \right) - \log P(Y|\theta^{(i)}) \\
 &\geq \sum_Z P(Z|Y, \theta^{(i)}) \log \frac{P(Y|Z, \theta)P(Z|\theta)}{P(Z|Y, \theta^{(i)})} - \log P(Y|\theta^{(i)}) \\
 &= \sum_Z P(Z|Y, \theta^{(i)}) \log \frac{P(Y|Z, \theta)P(Z|\theta)}{P(Z|Y, \theta^{(i)})P(Y|\theta^{(i)})}
 \end{aligned}$$

$$\text{令 } B(\theta, \theta^{(i)}) \triangleq L(\theta^{(i)}) + \sum_Z P(Z|Y, \theta^{(i)}) \log \frac{P(Y|Z, \theta)P(Z|\theta)}{P(Z|Y, \theta^{(i)})P(Y|\theta^{(i)})}$$

$$\text{则 } L(\theta) \geq B(\theta, \theta^{(i)})$$

- 即函数 $B(\theta, \theta^{(i)})$ 是 $L(\theta)$ 的一个下界, 而且

$$L(\theta^{(i)}) \triangleq B(\theta^{(i)}, \theta^{(i)})$$

- 任何可以使 $B(\theta, \theta^{(i)})$ 增大的 θ , 也可以使 $L(\theta)$ 增大。
- 为了使 $L(\theta)$ 有尽可能大的增长, 选择 $\theta^{(i+1)}$ 使 $B(\theta, \theta^{(i)})$ 达到极大, 即

$$\theta^{(i+1)} = \operatorname{argmax}_{\theta} B(\theta, \theta^{(i)})$$

现在求 $\theta^{(i+1)}$ 的表达式，省去对 θ 的极大化而言是常数的项


$$\begin{aligned}\theta^{(i+1)} &= \operatorname{argmax} \left(L(\theta^{(i)}) + \sum_Z P(Z|Y, \theta^{(i)}) \log \frac{P(Y|Z, \theta)P(Z|\theta)}{P(Z|Y, \theta^{(i)})P(Y|\theta^{(i)})} \right) \\ &= \operatorname{argmax} (\sum_Z P(Z|Y, \theta^{(i)}) \log(P(Y|Z, \theta)P(Z|\theta))) \\ &= \operatorname{argmax} (\sum_Z P(Z|Y, \theta^{(i)}) \log(P(Y, Z|\theta))) \\ &= \operatorname{argmax} Q(\theta, \theta^{(i)})\end{aligned}$$

等价于**EM**算法的一次迭代，即求**Q**函数及其极大化。

$$\begin{aligned}Q(\theta, \theta^i) &= E_Z[\log P(Y, Z|\theta)|Y, \theta^{(i)}] \\ &= \sum_Z \log P(Y, Z|\theta) P(Z|Y, \theta^{(i)})\end{aligned}$$

- **EM**算法是通过不断求解下界的极大化逼近求解对数似然函数极大化的算法。
- 两个函数在点 $\theta = \theta^{(i)}$ 处相等,
- 下一个点 $\theta^{(i+1)}$ 使函数 $B(\theta, \theta^{(i)})$ 极大化, 也使函数 $Q(\theta, \theta^{(i)})$ 极大化, 由于 $L(\theta) \gg B(\theta, \theta^{(i)})$, 函数 $B(\theta, \theta^{(i)})$ 的增加, 保证对数似然函数 $L(\theta)$ 在每次迭代中也是增加的。

- **EM**算法在点 $\theta^{(i+1)}$ 重新计算 Q 函数值, 进行下一次迭代。
- 在这个过程中, 对数似然函数 $L(\theta)$ 不断增大。



Homework

- 假设有3枚硬币，分别记作**A**，**B**，**C**。这些硬币正面出现的概率分别是 π, p 和 q 。进行如下掷硬币试验:先掷硬币**A**，根据其结果选出硬币**B**或硬币**C**，正面选硬币**B**，反面选硬币**C**;然后掷选出的硬币，掷硬币的结果，出现正面记作**1**，出现反面记作**0**;独立地重复**n**次试验($n = 10$)，观测结果如下:

1,1,0,1,0, 0,1,0,1,1

试选择不同的初值，例如, $\pi_0=0.46$ ， $p_0=0.55$ ， $q_0= 0.67$ ，求模型参数 $\theta=(\pi, p, q)$ 的极大似然估计。

THANK YOU!


如果 f 是凸函数， X 是随机变量，那么

$$E[f(X)] \geq f(EX)$$

特别地，如果 f 是严格凸函数，那么 $E[f(X)] = f(EX)$ 当且仅当 $p(x = E[X]) = 1$ ，也就是说 X 是常量。

这里我们将 $f(E[X])$ 简写为 $f(EX)$ 。

如果用图表示会很清晰：



这里需要解释的是 $E(X)$ 的值为什么是 $(a+b)/2$ ，因为有0.5的概率是 a ，0.5的概率是 b ，于是他的期望就是 a, b 的和的中间值了。同理在 y 轴上的值也是如此。

期望公式中Lazy Statistician规则

设 Y 是随机变量 X 的函数， $Y = g(X)$ (g 是连续函数)，那么



(1) X 是离散型随机变量，它的分布律为 $P(X = x_k) = p_k$, $k=1,2,\dots$ 。若 $\sum_{k=1}^{\infty} g(x_k)p_k$ 绝对收敛，则有

$$E(Y) = E[g(X)] = \sum_{k=1}^{\infty} g(x_k)p_k$$

(2) X 是连续型随机变量，它的概率密度为 $f(x)$ ，若 $\int_{-\infty}^{\infty} g(x)f(x)dx$ 绝对收敛，则有

$$E(Y) = E[g(X)] = \int_{-\infty}^{\infty} g(x)f(x)dx$$

$\text{Log}_a x$

	$a > 1$	$0 < a < 1$
图 象		
性 质	(1) 定义域 $\{x x>0\}$	
	(2) 值域 $\{y y \in \mathbf{R}\}$	
	(3) 当 $x=1$ 时, $y=0$, 即过定点 $(1,0)$	
	(4) 当 $x>1$ 时, $y>0$; 当 $0<x<1$ 时, $y<0$	(4) 当 $x>1$ 时, $y<0$; 当 $0<x<1$ 时, $y>0$
	(5) 在 $(0, +\infty)$ 上是增函数	(5) 在 $(0, +\infty)$ 上是减函数