

第五章 网络层

(约14学时)

主要内容

■ 概述

- ◆ 网络层的位置和作用
- ◆ 虚电路交换和数据报选路

■ 路由选择算法


- ◆ 距离矢量选路 (DVR)
- ◆ 链路状态选路 (LSR)
- ◆ 层次选路

■ 拥塞控制和网络互连

■ 因特网的网络层


- ◆ IP编址
- ◆ 包格式
- ◆ IPv6
- ◆ ICMP、ARP和DHCP
- ◆ 选路协议：RIP、OSPF和BGP
- ◆ IP组播
- ◆ 移动IP

网络层协议工作的环境




Store-and-Forward Packet Switching (存储转发分组交换)

网络层的位置和功能



网络层是实现端到端（主机-主机）传输的最低层


跳 (Hop) 的概念



经过一个路由器就是1跳


Next Hop: 下一跳

互联网中的数据链路层：逐跳传输



[Forouzan]


互联网中的网络层：主机-主机传输



主机-主机（端-端）

[Forouzan]

网络层的功能(1)




互连不同的网络，使得在传输层看起来是一样的
不同的网络：网络地址不同、实现技术可能不同、包格式可能不同

传输层不用考虑下层的物理网络（网络的个数及其具体技术对于传输层透明）

[Forouzan]


网络层的功能(2)



主机/路由器的地址必须是**唯一**且**统一**的 (统一的地址格式)
互联网上的两个设备不能有相同的地址 (每个接口一个地址，接口地址唯一)

[Forouzan]


网络层的功能 (3)



将上层的报文/消息封装、形成数据包，这是各层（物理层除外）都要提供的功能
在因特网里，打包由IP完成

[Forouzan]


网络层的功能(4)



网络层能够在任何数据链路层技术之上工作
不同的数据链路层网络支持的最大数据长度不同
网络层必须能够将传输层PDU进行分段/分片，分成更小的单元，以便能够在不同的数据链路层技术之上上传送

[Forouzan]


网络层的功能(5)



要把包发送到目的地，**下一跳（Next Hop）**是谁？
数据包不能自己选择路由；由连接**LAN/WAN**的路由器完成路由选择

[Forouzan]

源主机的网络层




源主机的网络层产生包，其中携带着源主机地址和目的主机地址

源主机还要检查路由表以确定路由信息（例如确定输出接口：如以太网或wifi）

[Forouzan]

路由器的网络层

负责为数据包选择路由




当一个包到达，路由器检查路由表，以确定包应该转发到哪个接口（下一跳是谁）

c. Network layer at a router

[Forouzan]

目的主机的网络层

负责验证包中的目的地址



b. Network layer at destination

目的主机要确定包中携带的**目的地址**和**自己**的地址相同

[Forouzan]

向传输层提供的服务


■ 设计目标

- ◆ 服务应该独立于路由器的技术
- ◆ 向传输层屏蔽路由器的数目、类型和拓扑结构
- ◆ 传输层可见的网络地址应该使用统一的编号方案，即使跨越多个LAN和WAN。


■ 两类服务

- ◆ 面向连接服务
- ◆ 无连接服务

交换技术



无连接服务的实现：数据报网络




R1的路由表

路由选择:
向哪里转发分组?

目的地	线路(下一跳)
R1	---
R2	R2
R3	R5
R4	R4
R5	R5

[Forouzan]

数据报子网的路由选择(1)



A's table (initially)

A	-
B	B
C	C
D	B
E	C
F	C

Dest. Line

A's table (later)

A	-
B	B
C	C
D	B
E	B
F	B

C's table


A	A
B	A
C	-
D	E
E	E
F	E

E's table

A	C
B	D
C	C
D	D
E	-
F	F

路由表是动态的，
周期性更新


数据报子网的路由选择(2)



包中需要携带完整地址；包到达可能乱序


面向连接服务的实现：虚电路网络

- 电路交换网络与数据报网络的交叉
- 在数据传输之前，先建立虚电路，并选择一条端到端的路径
- 提供面向连接服务
- 虚电路标识符 (VCI): 本地有效
 - ◆ 比地址短得多




[Forouzan]

虚电路的路由表示例(1)




[Forouzan]

虚电路的路由表示例(2)





[Forouzan]

虚电路子网的路由选择(1)



VC1: H1-A-C-E-F-H2
VC2: H3-A-C-E-F-H2

虚电路子网的路由选择(2)



● vc1: A--1--2--4--B

● vc2: A--1--3--5--C

虚电路 vs. 数据报

Issue	Datagram network	Virtual-circuit network
Circuit setup	Not needed	Required
Addressing	Each packet contains the full source and destination address	Each packet contains a short VC number
State information	Routers do not hold state information about connections	Each VC requires router table space per connection
Routing	Each packet is routed independently	Route chosen when VC is set up; all packets follow it
Effect of router failures	None, except for packets lost during the crash	All VCs that passed through the failed router are terminated
Quality of service 服务质量	Difficult	Easy if enough resources can be allocated in advance for each VC
Congestion control 拥塞控制	Difficult	Easy if enough resources can be allocated in advance for each VC

主要内容

■ 概述

■ 路由选择算法

- ◆ 路由选择和路由表概念

- ◆ 最优化原则

- ◆ 洪泛法(Flooding)

- ◆ Dijkstra的“最短路径”算法

- ◆ 距离矢量选路 (DVR)

- ◆ 链路状态选路 (LSR)

- ◆ 分级选路

■ 拥塞控制和互连互通

■ 因特网的网络层

路由选择：概述（1）

- 互联网 是多个网络的集合，通过路由器连接构成
- 一个数据包从原端发出到目的端可能经过多个路由器
- 收到一个包时，路由器将查询路由表。路由表给定了该包的最佳路径。
- 为实现高效查表，需要能够管理路由表的大小，并且处理如安全性之类的问题
 - ◆ 关键问题是如何设计路由表

路由选择：概述(2)

- 路由表可以是静态的或者动态的
 - ◆ 静态路由表 不会频繁变化

静态路由表包含人工输入的信息，通常不会改变

- ◆ 动态路由表 在网络中有变化的时候自动更新

动态路由表 使用RIP、OSPF或BGP等动态选路协议，周期性更新或者在必要时更新，

路由选择：概述(3)

- 选路算法：用于构造和更新路由表的算法
 - ◆ DVR, LSR, PVR
- 选路协议：在网络中有变故时让路由器通知其他路由器的规则或者规程的集合，多数协议是基于不同网络的路由器之间共享信息或整合信息
 - ◆ RIP, OSPF, BGP

路由表：下一跳选路

Routing table for host A

Destination	Route
Host B	R1, R2, Host B


Routing table for R1

Destination	Route
Host B	R2, Host B

Routing table for R2

Destination	Route
Host B	Host B

a. Routing tables based on route (完整路径)



Routing table for host A

Destination	Next Hop
Host B	R1

Routing table for R1

Destination	Next Hop
Host B	R2

Routing table for R2

Destination	Next Hop
Host B	—

b. Routing tables based on next hop

选路算法

- 路由选择和路由表的概念
- 最优化原则
- 洪泛法(Flooding)
- Dijkstra的“最短路径”算法
- 距离矢量选路 (DVR)
- 链路状态选路 (LSR)
- 分级选路

如何衡量选路算法？

■ （选路算法的）目标

- ◆ 正确
- ◆ 简单
- ◆ 健壮
- ◆ 稳定
- ◆ 公平
- ◆ 最优
 - 平均包延迟最小
 - 整个网络的吞吐量最大

■ 性能标准

- ◆ 最小开销，如跳数最少

选路算法的职责（功能）

- 负责为输入的数据包选择一条输出线路
 - ◆ 如果子网内部使用数据报方式，需要为每个到达的数据包选路
 - ◆ 如果子网内部使用虚电路方式，只在建立虚电路时进行路由选择，数据包将沿着预先建立的路由传输。
- 选路(Routing) 和转发(Forwarding)
 - ◆ 选路：根据某种算法，构造或更新路由表；
 - ◆ 转发：根据数据包的目的地址，查表确定输出端口，将数据包放到输出端口的队列中，交给数据链路层（网卡）

选路算法分类

■ 非自适应算法（静态选路）


- ◆ 在线下事先计算好路由的选择，当网络启动时下载到路由器中
- ◆ 不会基于对于当前业务量和拓扑结构的衡量或估计来进行路由选择

■ 自适应算法

- ◆ 在拓扑结构改变，通常也在业务量改变时，改变路由选择以反映对应的网络变化

最优化原则


- 如果路由器 **J** 在从路由器 **I** 到路由器 **K** 的最优路径上，则从 **J** 到 **K** 的最优路径也落在同一条路由上
 - ◆ 如果存在一条路由 r_x 比现有的 **J** 到 **K** 的路由 r_2 更优， r_x 将与 r_1 级联以改进 **I** 到 **K** 的路由
 - ◆ 与前提路由 $r_1 r_2$ 最优相矛盾



宿树/汇集树 (Sink Tree)


- 以目的节点为根，由所有源节点到目的节点的最优路由构成
- 没有环路，因此每个包在有限的跳数内会到达目的地
- 是衡量各选路算法的基准（ benchmark ）

汇集树示例



(a)

(a) 一个子网



(b)

(b) 路由器B的汇集树

主要的选路策略

■ 固定查表选路

- ◆ 为每对源节点-目的节点选择一条一直使用（永久）的路由

■ 洪泛/泛洪(flooding)

- ◆ 数据包发给每个邻居节点
- ◆ 到达的数据包将转发到除输入链路之外的每条链路

■ 随机选路

- ◆ 选择一条输出路径来转发输入的数据包
- ◆ 可以随机选择、也可以循环选择

■ 自适应选路

- ◆ 在网络发生变化时，路由选择随之变化
- ◆ 需要了解网络的信息
- ◆ 应用在几乎全部分组交换网络中


选路算法

- 路由选择和路由表的概念
- 最优化原则
- 洪泛法(Flooding)
- Dijkstra的“最短路径”算法
- 距离矢量选路 (DVR)
- 链路状态选路 (LSR)
- 分级选路


洪泛法：思路

- 无需路由表
- 无需网络信息
- 输入的数据包将转发到除输入链路之外的每条链路上
- 最终将有大量的副本到达目的地


洪泛法示例



(a) First hop



(b) Second hop



(c) Third hop

洪泛法：问题和解决方案

■ 问题

- ◆ 产生了大量的重复包

■ 解决方案

- ◆ 每个包的包头都包含一个跳计数器
 - 每经过一跳，计数器的值减一
 - 当计数器的值减到0时，则丢弃该数据包
 - 发送方将跳计数器的值初始化为从源端到目的端的路径长度或子网的直径（最大跳数）
- ◆ 源节点在每个包中放一个序列号
 - 每个路由器为每个源节点记录一个最大序列号（代表哪些序列号的包已经收到过）

洪泛法的特性

- 尝试所有可能的路由
 - ◆ 健壮性强
- 至少有一个包选择了最小跳数的路由
- 能访问到全部节点
 - ◆ 对于分发选路（路由）信息很有用

选路算法

- 路由选择和路由表的概念
- 最优化原则
- 洪泛法(Flooding)
- Dijkstra的“最短路径”算法
- 距离矢量选路 (DVR)
- 链路状态选路 (LSR)
- 分级选路

最短路径选路

■ 构建一个带权值的有向图

- ◆ 节点代表路由器
- ◆ 节点之间的边代表通信链路

■ 权值

- ◆ 跳数
- ◆ 地理距离（公里） **Geographic distance in kilometers**
- ◆ 平均排队时延和发送时延
- ◆ 距离、带宽、平均业务量、通信开销、平均队列长度、测量到的时延和其他因素的函数

■ Dijkstra算法

- ◆ 发现一对给定路由器之间的最短路径


Dijkstra算法

■ 发现一个给定源节点到其他所有节点的最短路径

■ 选路算法







- ◆ 1. 从本地节点（路由器）（即树根）开始
- ◆ 2. 将此节点的开销设为0，并使之成为第一个永久节点
- ◆ 3. 检查刚成为永久节点的每个邻居节点
- ◆ 4. 为每个节点计算累计开销，并设置为临时节点
- ◆ 5. 在临时节点的列表中
 - 找到具有最小累计开销的节点，设为永久节点
 - 如果一个节点可以从多个方向到达，选择具有最小累计开销的方向
- ◆ 6. 重复步骤3-5，直到每个节点都成为永久节点

Dijkstra算法的流程图




[Forouzan]

Dijkstra算法示例(1)



Dijkstra算法示例(2)




A	B	C	D	E	F	G	H	Permanent Node
∞	∞	∞	∞	∞	∞	∞	∞	
0	∞	∞	∞	∞	∞	∞	∞	A
0	2, A	∞	∞	∞	∞	6, A	∞	B
0	---	9, B	∞	4, B	∞	6, A	∞	E
0	---	9, B	∞	---	6, E	5, E	∞	G
0	---	9, B	∞	---	6, E	---	9, G	F
0	---	9, B	∞	---	---	---	8, F	H
0	---	9, B	10, H	---	---	---	---	C
0	---	---	10, H	---	---	---	---	D


使用Dijkstra算法可以得到什么？

节点A的路由表

Dest.	Cost	Next Hop
A	0	--
B	2	B
C	9	B
D	10	B
E	4	B
F	6	B
G	5	B
H	9	B



A的最短路径树



选路算法

- 路由选择和路由表的概念
- 最优化原则
- 洪泛法(Flooding)
- Dijkstra的“最短路径”算法
- 距离矢量选路 (DVR)
- 链路状态选路 (LSR)
- 分级选路

距离矢量选路(Distance Vector Routing)

■ 每个路由器维护一个路由表

- ◆ 到每个目的地的已知最优距离

 - 距离可能是跳数、时延...

- ◆ 使用哪条线路到达目的地 (下一跳/接口)

■ 通过与邻居交换信息来更新路由表

- ◆ 发送的路由信息: (目的地、距离)

 - 周期性发送 (RIP:30s)

- ◆ 当收到路由信息时,

 - 如果收到更好的路由, 则路由器更新路由表

 - 刷新现有路由 (上一周期的路由表被刷新)

- ◆ 删除过期的路由表项 (RIP: 180s)

DVR: 教材中的示例




Diagram (b) illustrates the calculation of the new estimated delay from J and the resulting new routing table for J.

Table 1: Vectors received from J's four neighbors

To	A	I	H	K
A	0	24	20	21
B	12	36	31	28
C	25	18	19	36
D	40	27	8	24
E	14	7	30	22
F	23	20	19	40
G	18	31	6	31
H	17	20	0	19
I	21	0	14	22
J	9	11	7	10
K	24	22	22	0
L	29	33	9	9

Below the table, the delay for each neighbor is calculated:

- JA delay is 8
- JI delay is 10
- JH delay is 12
- JK delay is 6

Table 2: New routing table for J

New estimated delay from J	Line
8	A
20	A
28	I
20	H
17	I
30	I
18	H
12	H
10	I
0	–
6	K
15	K

The new routing table for J is shown below the table.

以目的地**B**为例,

$$JB = JA + AB = 8 + 12 = 20$$


$$JB = JI + IB = 10 + 36 = 46$$

$$JB = JH + HB = 12 + 31 = 43$$

$$JB = JK + KB = 6 + 28 = 34$$

因此，选择**A**为下一跳节点

DVR示例2： 初始状态



Node A

Dest.	Cost	NextHop
B	2	B
C	7	C
D	∞	-

Node B

Dest.	Cost	NextHop
A	2	A
C	1	C
D	3	D


Node C

Dest.	Cost	NextHop
A	7	A
B	1	B
D	1	D

Node D

Dest.	Cost	NextHop
A	∞	-
B	3	B
C	1	C

示例2：第一次迭代 ($C \rightarrow A$)



Node A

Dest.	Cost	NextHop
B	2	B
C	7	C
D	8	C

Node B

Dest.	Cost	NextHop
A	2	A
C	1	C
D	3	D

$$D(A, D) = D(A, C) + D(C, D) = 7 + 1 = 8$$

($D(C, A)$, $D(C, B)$, $D(C, D)$)


Node C

Dest.	Cost	NextHop
A	7	A
B	1	B
D	1	D


Node D

Dest.	Cost	NextHop
A	∞	-
B	3	B
C	1	C

示例2：第一次迭代 ($B \rightarrow A$, $C \rightarrow A$)



示例2：第一次迭代结束



Node A

Dest.	Cost	NextHop
B	2	B
C	3	B
D	5	B

Node B

Dest.	Cost	NextHop
A	2	A
C	1	C
D	2	C


Node C

Dest.	Cost	NextHop
A	3	B
B	1	B
D	1	D

Node D

Dest.	Cost	NextHop
A	5	B
B	2	C
C	1	C

示例2：第二次迭代结束



Node A

Dest.	Cost	NextHop
B	2	B
C	3	B
D	4	B

Node B

Dest.	Cost	NextHop
A	2	A
C	1	C
D	2	C


Node C

Dest.	Cost	NextHop
A	3	B
B	1	B
D	1	D

Node D

Dest.	Cost	NextHop
A	4	C
B	2	C
C	1	C

示例2：第三次迭代结束



Node A

Dest.	Cost	NextHop
B	2	B
C	3	B
D	4	B

Node B

Dest.	Cost	NextHop
A	2	A
C	1	C
D	2	C

Node C

Dest.	Cost	NextHop
A	3	B
B	1	B
D	1	D

Node D

Dest.	Cost	NextHop
A	4	C
B	2	C
C	1	C

Nothing changes → algorithm terminates

DVR的特点及问题

■ 3个关键特点



- ◆ 与邻居共享整个网络的信息
- ◆ 仅与邻居节点共享，把已知的网络信息发送到所有接口
- ◆ 每隔一段时间共享

■ 缺点

- ◆ 收敛慢
- ◆ 好消息扩散快，坏消息传播慢


DVR: 无穷计数问题

■ 也称为“无限环路问题”



坏消息传播慢

DVR: 无限环路示例



对于一个目的节点，路由器只知距离，不知路径

DVR: 小结

■ 应用于下列协议

- ◆ 选路（路由）信息协议RIP
- ◆ Cisco的EIGRP (增强的内部网关选路协议)

■ DVR的问题

- ◆ 当X告诉Y自己有一条路径时，Y没办法知道自己是否在这条路径上（即是否存在环路）
- ◆ 基于谣传的选路

■ 改进：基于路径的选路

- ◆ BGP-4 (边界网络协议)
- ◆ IDR (域间选路协议)


选路算法

- 路由选择和路由表的概念
- 最优化原则
- 洪泛法(Flooding)
- Dijkstra的“最短路径”算法
- 距离矢量选路 (DVR)
- 链路状态选路 (LSR)
- 分级选路

链路状态选路(Link State Routing)

- 在LSR中，路由器与网络内的每一个路由器共享关于邻居的信息
- 路由器在本地构造了已知的部分网络拓扑结构之后，放在链路状态包LSP中，并发送给每个路由器
- 理解LSP的3个关键点：
 - ◆ 共享部分网络拓扑结构
 - ◆ 与每个路由器共享
 - ◆ 在网络中发生变化时共享
- 从收到的LSP，路由器可以获知整个网络的拓扑结构，然后可以计算出自己到其他路由器的最短路径

LSR: 路由器知道什么？



路由器知道**全网**的拓扑结构

LSR: 操作过程

■ 每个路由器必须完成下列任务:

1. 发现邻居，获得邻居的网络地址
2. 测量到每个邻居的时延或开销
3. 构造一个包（**LSP**: 链路状态包），包含它刚学习到的信息（部分网络拓扑）
4. 将**LSP**可靠地发给网络中所有其他路由器
5. 计算到每个其他路由器的最短路径

第1步：学习邻居的信息

■ HELLO包

- ◆在广播网络中，广播特殊的HELLO包
- ◆对于点到点网络，将HELLO包直接发送给邻居（单播）

■ 邻居发回响应，告知自己的名字或地址


- ◆名字(路由器ID) 必须是全球唯一的

■ 简化拓扑结构

- ◆当两个或多个路由器连接到一个LAN上或者其他多路访问网络上


如何对于LAN建模

将LAN看作一个虚拟节点



(a)

(a) 一个LAN和9个路由器



(b)

(b) (a)对应的图

第2步：测量线路开销


■ 线路开销：即到邻居的时延

- ◆ 用环回时间来测量 (ECHO 包)

- ◆ 带宽


- ◆ 一个问题是在测量时延时是否要考虑负载？

- 路由表可能震荡（在多条路由之间摇摆），导致路由不稳定及其他的潜在问题



路由振荡，
导致不稳定

第3步：构造链路状态包



(a) A subnet. (b) The link state packets for this subnet

■ 什么时候构造LSP

◆ 周期性构造

◆ 当某些重要的事情发生时

➤ 例如：一条线路或邻居崩溃了，又重新启动；
或者线路/邻居的属性改变了

关于链路状态包中的序号和年龄

■ 序号：用于检查收到的LSP是不是新的

- ◆ 如果LSP是新的，以洪泛方式转发
- ◆ 如果LSP是重复的，丢弃
- ◆ 如果一个新到达的包的序号比已收到的报的最大序号小，则改包被判定为过时，被拒绝
- ◆ 如果一个路由器死机了，然后重启.....

■ 年龄：用于删除循环的LSP

- ◆ 如果一个路由器崩溃了
- ◆ 如果一个路由器改变了路由器ID
- ◆ 如果一个路由器要删除一个LSP

第4步：分发链路状态包


■ 需求

- ◆ 可靠地分发LSP Distributing the LSP reliably

■ 基本分发算法

- ◆ 使用洪泛法(flooding) 来分发 LSP
- ◆ 为防止路由器-路由器的线路上出现差错，所有LSP都要进行确认

LSP示例



(a)

Link		State		Packets	
A		B		C	
Seq.		Seq.		Seq.	
Age		Age		Age	
B	4	A	4	B	2
E	5	C	2	D	3
		F	6	E	1

(b)


Source	Seq.	Age	Send flags			ACK flags			Data
			A	C	F	A	C	F	
A	21	60	0	1	1	1	0	0	
F	21	60	1	1	0	0	0	1	
E	21	59	0	1	0	1	0	1	
C	20	60	1	0	1	0	1	0	
D	21	59	1	0	0	0	1	1	

节点B收到的LSP的记录


第5步：计算新路由

- 当路由器收到全部LSP后，就可以构造全网的拓扑结构图
 - ◆ 每条链路在图中表示两次（有向图），每次表示一个方向；其权值可以取平均值，也可以两个方向分别表示
- 在本地执行Dijkstra算法 以构造到所有可能目的地的最短路径
- 将算法的结果安装到路由表中


LSR: 示例




(a) 网络拓扑



(b) 有向图



以路由器F为根的最短路径树



Dest	NextHop
L1	D
L2	G
W1	D
W2	D
W3	-- (direct)
W4	D
W5	-- (direct)
W6	G

F 的路由表

LSR的应用

■ IS-IS (中间系统-中间系统)

- ◆可同时支持多个网络层协议
- ◆如: DECnet, ISO CLNP, IP, AppleTalk, Novell NLSP (IPX)


■ OSPF (开放的最短路径优先)

- ◆在IS-IS出现的几年后设计和实现
- ◆只能用于IP

选路算法

- 路由选择和路由表的概念
- 最优化原则
- 洪泛法(Flooding)
- Dijkstra的“最短路径”算法
- 距离矢量选路 (DVR)
- 链路状态选路 (LSR)
- 分级选路

层次选路/分级选路 (1)



1A→5C

(a)

Full table for 1A

Dest.	Line	Hops
1A	—	—
1B	1B	1
1C	1C	1
2A	1B	2
2B	1B	3
2C	1B	3
2D	1B	4
3A	1C	3
3B	1C	2
4A	1C	3
4B	1C	4
4C	1C	4
5A	1C	4
5B	1C	5
5C	1B	5
5D	1C	6
5E	1C	5

(b)

Hierarchical table for 1A

Dest.	Line	Hops
1A	—	—
1B	1B	1
1C	1C	1
2	1B	2
3	1C	2
4	1C	3
5	1C	4

可能是
次优路由

(c)

分级选路(2)

对于一个有**720**个路由器的网络，

- 如果不分级
 - ◆ **720**个路由表项
- 如果分成**24**个区，每个区**30**台路由器（一共**53**个表项）
 - ◆ **30**个本地表项
 - ◆ **23**个远程表项
- 如果采用三级分级，有**8**个簇、每个簇包含**9**个区，每个区内包含**10**台路由器（一共 **25** 个表项）
 - ◆ **10**个本地表项
 - ◆ 有**8**个表项，每个表项包含了到本簇其他区的选路信息
 - ◆ 到其他簇，有**7**个表项

选路算法小结

■ 距离矢量选路 vs 链路状态选路

	DVR	LSR
共享什么信息？	路由表（目的地址和距离）	已知网络拓扑（LSP）
和谁共享？	邻居	网络中的所有路由器
何时共享？	周期性	网络中有（拓扑或负载）变化时
路由器知道什么？	只知距离，不知路径	整个网络的拓扑结构
有无穷计数问题吗？	有	无

■ 分级选路：简化路由表

◆ 域内：选路到路由器；域间：选路到域


主要内容

- 概述
- 路由选择算法
- 拥塞控制和互连互通
 - ◆ 拥塞控制算法
 - ◆ QoS
 - ◆ 互通互联
- 因特网的网络层

什么是拥塞？


- 通俗地说：“太多源主机太快地发送太多数据，以至于网络不能处理”（资源不足）
- 如果网络上的负载（发送到网络中的数据包数量）超过了网络的容量（网络能够处理的数据包数量）

如果主机提供了太多业务量，将发生拥塞，性能将严重下降



拥塞的原因

- 任何有等待或排队的系统，都有可能发生拥塞



- 如果包的到达率比包处理速率高，输入队列将越来越长
- 如果包离开的速率比处理速率高，输出队列将越来越长

拥塞的症状


■ 导致拥塞的次要因素:

- ◆ CPU处理速度慢
- ◆ 链路带宽低
- ◆ 缓冲队列短


■ 拥塞症状:

- ◆ 时延变长（在路由器缓存中排队）
- ◆ 包丢失（路由器缓存溢出）

网络的性能：时延和吞吐量



a. Delay as a function of load



b. Throughput as a function of load

■ 拥塞控制涉及两个衡量网络性能的参数

◆时延：排队时延、处理时延、传播时延

◆吞吐量：单位时间内通过网络的数据包数量

拥塞控制方法


■ 两类解决方案

■ 增加资源

- ◆ 网络提供
- ◆ 业务量感知的路由

■ 减少负载

- ◆ 接纳控制
- ◆ 业务量减速
- ◆ 负载掉落



网络提供

- 规划、调整网络，以适应业务量(负载)
- 构造一个可以与承载的业务量匹配良好的网络
- 当严重拥塞时，动态增加资源
- 对于经常性利用率过高的链路和路由器，应尽快升级

业务量感知的选路


■ 普通的选路机制

- ◆ 使用 固定链路权值，适应拓扑结构的变化，但不适应负载的改变

■ 基于业务量模式选路

- ◆ 链路权值：链路带宽、传播时延、加上度量出的负载或平均排队时延的综合函数
- ◆ 考虑负载 以使得业务量绕开热点路径


■ 可能导致路由震荡，不稳定



接纳控制

- 在虚电路网络中广泛使用
- 思路：如果增加的业务量会导致网络拥塞，就不允许建立虚电路
- 关键问题：如果描述业务量？
- 配备业务量描述（通过 漏桶 或 令牌桶），网络可以决定是否接纳新的虚电路
- 与业务量感知的选路相结合：在建立VC时，考虑绕开业务量热点的路径

为新VC选择绕开拥塞区域的路径



业务量感知的选路

业务量减速/节流

■ 基于反馈的解决方案

■ 第1步：路由器检测到拥塞，通过

- ◆ 输出链路的利用率
- ◆ 路由器内部的数据包排队的缓存（队列长度）
- ◆ 由于缓存不足而丢失的数据包的数量

对排队时延的估测：

EWMA (指数加权移动均值)

$$d_{\text{new}} = \alpha d_{\text{old}} + (1 - \alpha)s$$

- ◆ d : 近期队列长度
- ◆ s : 即时队列长度的样本
- ◆ $0 < \alpha < 1$ 平衡因子

业务量减速

■ 第2步：传送关于拥塞的信息

- ◆ 向源主机发一个数据包 (**Choke Packet**, 抑制分组), 告知发现拥塞的包所对应的目的主机
- ◆ 给原始的数据包打上标签, 以免产生更多的抑制分组
- ◆ 路由器只以较低速率发送抑制分组, 以免增加网络中的负载

■ 第3步：调整系统操作



- ◆ 收到抑制分组, 源主机可以将发送给对应目的主机的业务量减少 $x\%$ (例如 50%)

其它反馈机制:

逐跳反压

a) 普通抑制分组：只有主机响应


b) 逐跳反压：沿途
每一跳（路由器）
都响应



其他反馈机制：ECN

■ 显式拥塞通知

- ◆ IP和TCP使用
- ◆ IP包头的两个比特用于记录该包是否遇到拥塞
- ◆ 检测到拥塞的路由器在转发时给数据包加上标记
- ◆ 作为显式拥塞通知，目的主机在下一个回应的数据包中，将标记反馈回源主机



负载掉落

■ 丢包

◆ 路由器由于数据包而不胜负荷时，把这些包丢掉

■ 策略：丢掉哪些包？

◆ 随机丢包

◆ 红酒法 **vs.** 牛奶法

➤ 旧包 **vs.** 新包，哪一个更重要？

➤ 示例： 文件传输 **vs.** 多媒体

◆ 智能丢包

➤ 示例：携带选路信息的包更重要

➤ 示例：视频压缩算法，如**MPEG**

▣ 完整的视频帧 **vs.** 只包含与完整帧差别的后续帧

➤ 需要源主机合作： 标记数据包


因特网的负载掉落: RED

- Random Early Detection (随机早期检测)
- 在情况变得极差之前丢包
 - ◆ 当某条线路的平均队列长度超过阈值时, 就认为该线路拥塞, 将随机丢弃少量包
- 怎么将问题通知源主机?
 - ◆ 路由器只是丢弃选中的包
 - ◆ 相关源主机在没有收到ACK时, 发现包丢失, 隐式通知
- 源主机的反应是降低发送速率
 - ◆ 对于无线网络, 包丢失更多的原因是无线链路上的噪声, 因此不能使用这种方法

流量控制 vs. 拥塞控制

■ 流量控制

- ◆ 避免淹没接收方
- ◆ 局部问题，只涉及通信双方：发送方和接收方



■ 拥塞控制

- ◆ 避免网络拥塞
- ◆ 全局问题，涉及路径上所有主机/节点

小结：拥塞控制

- 拥塞：网络中的负载超出了网络的容量
- 现象：传输时延增加，数据包丢失
- 网络层的拥塞控制方法
 - ◆ 增加资源
 - ◆ 降低负载
 - 接纳控制（只限于虚电路网络）
 - 业务量减速
 - (1) 路由器发现拥塞
 - (2) 通知源主机 (发送choke packets或ECN)
 - (3) 源主机降低发送速率
 - 负载掉落(路由器丢包): RED

主要内容

- 概述
- 路由选择算法
- 拥塞控制和互连互通
 - ◆ 拥塞控制算法
 - ◆ QoS
 - ◆ 互通互联
- 因特网的网络层

主要的服务质量参数

■ 可靠性

- ◆ 包差错率

- ◆ 包丢失率

■ 时延：从发送第1个比特到最后1个比特被接收的时间

■ （时延）抖动Jitter：属于同一个流的各包时延的差值

■ 带宽：最大数据率

不同应用的QoS需求

Application	Reliability	Delay	Jitter	Bandwidth
E-mail	High	Low	Low	Low
File transfer	High	Low	Low	Medium
Web access	High	Medium	Low	Medium
Remote login	High	Medium	Medium	Low
Audio on demand	Low	Low	High	Medium
Video on demand	Low	Low	High	High
Telephony	Low	High	High	Low
Videoconferencing	Low	High	High	High

提高QoS的技术

- 业务量整形
- 分组（包）调度
- 接纳控制
- 资源预留


业务量/流量整形

■ 问题

- ◆ **业务量突发**: 主机不规律地发送数据包, 可能导致网络中出现拥塞

■ 业务量整形

- ◆ 调整数据发送的**平均速率** (和突发性), 使业务量平滑 (去突发)



漏桶和令牌桶







Figure 5-28. (a) Shaping packets. (b) A leaky bucket. (c) A token bucket.

漏桶算法




漏桶示例

■ 将不规则的包流变成规则的流

◆ 将突发平滑

◆ 减少拥塞的可能性

■ 以字节计数的漏桶




突发数据

漏桶的输出

■ 局限性： 桶满时，则后续数据被丢弃

令牌桶算法

- 令牌桶允许空闲的主机**积累**信用（令牌）备用
- 令牌桶**允许**突发，但不超过调整后的最大长度



空闲时，收集令牌，之后可以用于发送突发的数据包（不超过令牌桶允许的长度）

漏桶 vs. 令牌桶

■ 突发性

- ◆ 漏桶 算法强制以固定的平均速率模式输出，而不管业务量的突发性如何
- ◆ 令牌桶 在输出的数据流中允许一定的突发性

■ 当桶满时，

- ◆ 令牌桶 扔掉令牌，但不丢弃数据包
- ◆ 漏桶 算法丢弃数据包

令牌桶示例




Figure 5-29. (a) Traffic from a host. Output shaped by a token bucket of rate 200 Mbps and capacity (b) 9600 KB and (c) 0 KB. Token bucket level for shaping with rate 200 Mbps and capacity (d) 12800KB (e) 9600 KB, and (f) 0 KB.

以最大速率突发的长度

经过令牌桶之后的突发数据持续时间:

突发长度 **S** 秒

令牌桶容量 **B** 字节

令牌到达速率 **R** 字节/秒

最大输出速率 **M** 字节/秒

输出的突发最大量为: **B + RS** 字节

S秒以最大速率突发的数据量为 **MS** 字节

$$B + RS = MS$$

$$S = B / (M - R)$$

如果 $B = 9600\text{KB}$, $M = 125 \text{ MB/sec}$, $R = 25 \text{ MB/sec}$
则 $S = 96 \text{ ms}$

分组（包）调度

■ 流

- ◆ 从某个源主机发往某个目的主机的一系列数据包
- ◆ 假定属于一个流的数据包都选择同样的路由


■ 分组调度：在竞争的流之间，为一个流的包分配路由器资源

■ 算法

- ◆ **FIFO**队列
- ◆ 优先级队列
- ◆ 公平队列
- ◆ 公平加权队列


FIFO: 先进先出队列

- 先进先出，或先来先服务（FCFS）
- 丢弃尾部：当队列满时，新到达的包将被丢弃



FIFO: First In, First Out


优先级队列




- 先给包分配一个**优先级**。每个优先级有**单独的队列**
- 当有空闲线路时，首先处理最高优先级的队列中的包
- **QoS较好**：诸如多媒体的高优先级业务量能以较小的时延到达目的地
- 潜在问题：低优先级数据可能一直等待，不公平

公平队列

- 以循环方式来处理包（轮流处理每个队列中的包）



公平加权队列



- 优先级队列 + 公平队列 (按权值轮流)
- 队列的权值基于优先级，高优先级意味着高权值
- 系统轮流处理每个队列，按权值选择一次处理的包的个数

WFQ 示例




Figure 5-31. (a) Weighted Fair Queueing. (b) Finishing times for the packets.

$$F_i = \max(A_i, F_{i-1}) + \frac{L_i}{W}$$

F: finish time, A: Arrival time, L: length of packet, W: weight

资源预留和接纳控制

■ 资源预留

- ◆ 带宽
- ◆ 缓存空间
- ◆ CPU周期

流：同一对源/目的主机之间的多个数据包

■ 流协商

- ◆ 发送主机、接收主机和路径沿途所有路由器都参与协商

■ 流描述

- ◆ 描述一个流对网络的要求
- ◆ 源主机产生
- ◆ 沿途路由器和目的主机可修改

Parameter	Unit
Token bucket rate	Bytes/sec
Token bucket size	Bytes
Peak data rate	Bytes/sec
Minimum packet size	Bytes
Maximum packet size	Bytes

与路由器资源相关的流描述




Figure 5-33. Bandwidth and delay guarantees with token buckets and WFQ.

给每个流的权值 W 足够大，保证流以 R 速率输出时不会排队

QoS小结

■ 性能指标：带宽、时延、时延抖动、可靠性

■ 提高QoS的方法

◆ 业务量/流量整形：去突发

漏桶 vs. 令牌桶

漏桶也可用于traffic policing(流量监管)

◆ 分组/包调度

➤ FIFO(先进先出)

➤ 优先级队列(PQ)

➤ 公平队列(FQ)

➤ 公平加权队列 (WFQ)

主要内容

- 概述
- 路由选择算法
- 拥塞控制和互连互通
 - ◆ 拥塞控制算法
 - ◆ QoS
 - ◆ 互通互联
- 因特网的网络层

网络互连

- 不同的网络、不同的协议

- ◆ Ethernet、线缆网络之上的因特网、固定电话网、移动电话网、802.11、802.16、ATM, ...

- 互连的目的

- ◆ 允许任一网络的用户与所有其他网络的用户通信


- 互联网：两个或更多的网络相连

网络有哪些不同之处


Item	Some Possibilities
Service offered	Connectionless versus connection oriented
Addressing	Different sizes, flat or hierarchical
Broadcasting	Present or absent (also multicast)
Packet size	Every network has its own maximum
Ordering	Ordered and unordered delivery
Quality of service	Present or absent; many different kinds
Reliability	Different levels of loss
Security	Privacy rules, encryption, etc.
Parameters	Different timeouts, flow specifications, etc.
Accounting	By connect time, packet, byte, or not at all

如何连接网络

■ 相同网络层的不同网络相连



A packet crossing different networks




Network and link layer protocol processing

MPLS: 多协议标签交换

在不同层次互连

- 第1层: 中继器、HUB
- 第2层: 网桥、交换机
 - ◆ 协议翻译, 如Ethernets/802.11
- 第3层: 路由器 (包翻译)
- 第4层: 传输网关
 - ◆ TCP/无线TCP
- 4层以上: 应用网关
 - ◆ Email: RFC 5822/X.400
 - ◆ 即时消息网关

交换机 vs. 路由器




LAN交换机：基于**MAC**地址转发整个帧，

路由器：从帧中取出数据包，使用**3层地址**确定如何转发

隧道

- ◆源主机和目的主机在相同类型的网络上，但中间是不同的网络
- ◆源主机发出的包，封装在中间网络的包中



源主机与目的主机网络协议相同，中间网络不同
用中间网络的协议封装源主机发送的数据包

互联网选路

■ 两级选路算法

- ◆ 每个网络内部，使用域内或内部网关协议选路
- ◆ 在组成互联网的各网络之间，使用域间或外部网关协议选路

■ 在因特网协议中学习

为什么要分段/分片? MTU不同


- **MTU**: 最大传输单元
- **MTU**由谁确定
 - ◆ 硬件（例如 以太网的帧长）
 - ◆ 操作系统（例如缓存大小为**512**字节）
 - ◆ 协议（如包长度字段的比特数）
 - ◆ 与某些国家标准兼容
 - ◆ 限制**MTU**以减少出错导致的重传
 - ◆ 限制**MTU**以防止一个包占用信道太长时间
- 如何分段?
 - ◆ 在**IP**一节学习

主要内容

- 概述
- 路由选择算法
- 拥塞控制和网络互连
- 因特网的网络层
 - ◆ IP编址
 - ◆ 包格式
 - ◆ IPv6
 - ◆ ICMP、ARP和DHCP
 - ◆ 选路协议：RIP、OSPF和BGP
 - ◆ IP组播
 - ◆ 移动IP

OSI


TCP/IP



因特网的网络层的设计原则


- 确保能工作
- 保持简单
- 明确选择一种方案
- 使用模块化
- 接受异构性
- 避免静态选项和参数
- 寻求良好的设计，不需要完美
- 对发送方严格，对接收方宽容
- 考虑可扩展性
- 考虑性能和开销

因特网的准体系结构




网际互连协议IP

- 应用最广泛的网络互通协议
- 无连接的网络层协议
- 基于数据报选路
- 提供尽力而为服务，不可靠！
- IP的选路混合了层次选路、距离矢量选路和链路状态选路



[Forouzan]

IP的组件



IP的设计问题

■ 设计需求：适应不同网络的差异

- ◆不同的编制方案

 - 使用 统一的全局地址

- ◆不同的最大包长

- ◆不同的网络接入机制

- ◆不同的超时时间

- ◆不同的传输模式（面向连接、无连接）

- ◆差错控制


- ◆流量控制

IPv4的编址

- 分类地址：1981
- 子网：1985
- 超网：1993
- 无类别地址：1995

IPv4地址


- 因特网地址（**IP**地址）：用于标识连接到因特网的每个设备的网络层标识符
- 32位、点分十进制记法



- 统一编址
- 对每个网络接口唯一，与物理地址无关，定义到因特网的一个连接
- 如果一台主机/路由器有两个接口连接到因特网，就有两个**IP**地址
- 两类编址： 分类的 vs. 无类别的

分类地址


- IP在A类、B类和C类地址，至少传统上采用两级层次化编址机制：网络号(net-id) + 主机号(host-id)




网络地址

- 网络地址是地址块中的第一个地址，是分配给网络所属的机构
- 网络号部分保留，主机号部分为0
- 对网络中的任一个地址应用默认/缺省掩码，就可以得到网络地址
 - ◆ 将该IP地址与子网掩码“按位与”
- 默认掩码
 - ◆ A类：255.0.0.0
 - ◆ B类：255.255.0.0
 - ◆ C类：255.255.255.0

网络地址示例



网络地址的用途



在进行路由选择时，外部世界以**网络地址**来识别网络，而不是单独的各主机的**IP地址**

路由选择使用网络地址


[Forouzan]

特殊的IP地址

0 0																																This host								
0 0								...								0 0								Host																A host on this network
1 1																																Broadcast on the local network								
Network																1 1 1 1				...								1 1 1 1				Broadcast on a distant network								
127								(Anything)																								Loopback								
																																环回地址								


子网划分

- 目的：更有效地管理**IP**地址和对为数据包选路
- 在**内部使用**上，一个网络分成几个部分；但**对外部**世界仍然是一个网络，以**网络地址**为标识
 - ◆ 子网划分对于外部不可见
- 子网使用**部分主机号**来标识物理网络




子网掩码

- 路由器如何知道网络地址？
 - ◆ 使用 子网掩码.
- 在选路时将目的地址与子网掩码按位“与”
- 已知源IP地址、目的IP地址和子网掩码，可知
 - ◆ 此IP包是发给同一个子网中的主机
 - ◆ 还是发给另一个网络中的主机




子网划分示例(1)



[Forouzan]

子网划分示例(2)

一个校园网，包含不同院系的LAN



子网掩码: 255.255.240.0


从子网掩码可以知道什么？

➤ 该子网中的**IP**地址数

超网划分

- **C类地址**的问题：地址块内太小，难以满足一个机构/单位的需求
- 解决方案：超网
 - ◆ 将几个连续的**C**类地址块合并，以建立一个大地址块
 - ◆ 即几个网络合并成为一个**超网**
- 合并的**C**类网络个数一定是**2**的幂次
- 在地址空间上必须**连续**（地址块之间不能有空隙）


超网划分示例



超网掩码: 255.255.252.0

[Forouzan]

子网掩码、默认掩码与超网掩码




[Forouzan]

无类别地址

- 地址按A、B、C分类一直使用到90年代中期
- 分类地址的问题
 - ◆ 因特网持续的指数级增长导致地址空间将耗尽
 - ◆ 地址空间使用低效
 - ◆ 因特网的路由表过大
- 解决方案：无类别地址（始于1996年）
- 思路：采用可变长地址块，不分类

Address Space



无类别域间选路CIDR

■ CIDR地址格式：“/前缀”记法

a.b.c.d/x, where x is # bits in network portion of address



■ 编址规则

- ◆ 一个网络（子网）的地址数量一定是**2**的幂次
- ◆ 起始地址一定能够**整除**地址个数
 - 例如，如果一个子网包含**4**个地址，起始地址一定能整除**4**

CIDR前缀与点分十进制的对应


CIDR Notation	Dotted Decimal	CIDR Notation	Dotted Decimal
/1	128.0.0.0	/17	255.255.128.0
/2	192.0.0.0	/18	255.255.192.0
/3	224.0.0.0	/19	255.255.224.0
/4	240.0.0.0	/20	255.255.240.0
/5	248.0.0.0	/21	255.255.248.0
/6	252.0.0.0	/22	255.255.252.0
/7	254.0.0.0	/23	255.255.254.0
/8	255.0.0.0	/24	255.255.255.0
/9	255.128.0.0	/25	255.255.255.128
/10	255.192.0.0	/26	255.255.255.192
/11	255.224.0.0	/27	255.255.255.224
/12	255.240.0.0	/28	255.255.255.240
/13	255.248.0.0	/29	255.255.255.248
/14	255.252.0.0	/30	255.255.255.252
/15	255.254.0.0	/31	255.255.255.254
/16	255.255.0.0	/32	255.255.255.255

Figure 10.11 Dotted decimal mask values for all possible CIDR prefixes.

CIDR: 路由聚合/汇聚


■ CIDR允许路由聚合

◆ 使路由表减小



问题：地址空间被放大

路由聚合示例



网内的地址数与可分配(可用)地址

- 网络地址: $x.x.x.x/m$
- 网络号 m 位, 主机号 $=32-m=n$ 位
- 该网络内共有 2^n 个地址
- 其中第一个地址 (主机号为全0) 为网络地址
最后一个地址 (主机号为全1) 为广播地址
- 可分配 (可用) 地址数: 2^n-2


NAT: 网络地址翻译

- 问题: IP地址短缺
- 解决方案: 使用预留的私有/专用地址
 - ◆ 10.0.0.0 - 10.255.255.255/8
 - ◆ 172.16.0.0 - 172.31.255.255/12
 - ◆ 192.168.0.0 - 192.168.255.255/16
- NAT路由器将内部源IP地址转换为全局IP地址
- NAT盒子经常与防火墙结合在一个设备中
- NAT路由器也对源TCP/UDP端口进行转换

NAT 示例




NAT路由器负责私有地址和全局地址的转换



[Forouzan]

地址翻译示例



[Forouzan]

如果两个本地主机同时访问一个外部主机呢？

■ 使用端口号

◆ 违背了分层原则（上层对下层透明）

Translation Table

<i>Private Address</i>	<i>Private Port</i>	<i>External Address</i>	<i>External Port</i>	<i>Transport Protocol</i>
172.18.3.1	1400	25.8.3.2	80	TCP
172.18.3.2	1401	25.8.3.2	80	TCP
...	...	...	...	...

[Forouzan]


NAT盒子的位置和操作

■ 对于输出的包

- ◆ 源地址**10.x.y.z** → 客户的**真实地址**（全局地址）
- ◆ **源端口** → NAT盒子的翻译表（65536行）中的一个索引

■ 对于输入的包

- ◆ **源端口** 用作 **索引** 来查找NAT盒子的映射表（翻译表）
- ◆ 将**内部IP地址(10.x.y.z)** 和 **原始源端口号**插入数据包



IP地址小结

- 32位、点分十进制记法、分两级：网络号+主机号
- 网络地址：用于路由选择
- 分类地址：A、B、C类
 - ◆ 每类地址块固定大小，不灵活且浪费地址
 - ◆ 默认掩码
- 子网划分：使用部分主机号
 - ◆ 子网掩码
- 超网划分：使用部分网络号
 - ◆ 超网掩码
- 如何防止地址耗尽？
 - ◆ 无类别地址：CIDR、/前缀记法
 - ◆ 重用私有地址：NAT

关于**IP**地址我们要掌握什么？

- “网络地址/前缀”的含义
- 已知网络需要的地址数（主机数），能够分配**IP**地址空间
- 把多个网络聚合成一个网络
- 子网掩码的作用：计算出网络地址
- 已知子网掩码(“/前缀”), 可以知道网络中有多少个**IP**地址，多少个可用地址
- 已知一个数据报的目的**IP**地址和子网掩码，可以获得目的网络地址，并根据该地址查路由表确定如何转发该**IP**包
- 注意**最长前缀匹配法**

IP的设计问题

■ 设计需求：适应不同网络的差异

- ◆ 不同的编制方案

- ◆ 不同的最大包长

 - Fragmentation/Reassembly

- ◆ 不同的网络接入机制

- ◆ 不同的超时时间

- ◆ 不同的传输模式（面向连接、无连接）

- ◆ 差错控制


- ◆ 流量控制

主要内容

- 概述
- 路由选择算法
- 拥塞控制和网络互连
- 因特网的网络层
 - ◆ IP编址
 - ◆ 包格式
 - ◆ IPv6
 - ◆ ICMP、ARP和DHCP
 - ◆ 选路协议：RIP、OSPF和BGP
 - ◆ IP组播
 - ◆ 移动IP

IP数据报

■ 独立于硬件




↑
表示以太网帧内的数据
是IP 包

在以太网帧中封装IP数据报

IP包头

包头长度字段的单位是4字节


定义数据报的分类，用于支持QoS



通过计数递减来控制数据报传输的最大跳数

包头长度+数据长度
单位是字节


协议字段



- 定义使用**IP**层服务的上层协议
- **IP**数据报可以封装几个高层协议，对**TCP**协议字段值=6、**UDP**=17、**ICMP**=1、**IGMP**=2、**OSPF**=89
- 说明了在目的地，**IP**数据报的数据应该交给哪个协议实体

[Forouzan]

校验和/检验和概念 (RFC 1071)



RFC1071的算法描述

- 总体上说，因特网的校验和算法非常简单：
 - ◆ (1) 要校验的数据中，一对相邻的八位组形成一个**16位**整数，可以计算出这些**16位**整数的**1的补码和**
 - ◆ (2) 要产生校验和，校验和字段先清空，计算相关字节的“**1的补码和**”，将该和放入校验字段
 - ◆ (3) 要检查校验和，在同样的字节集（包括校验字段本身）中计算“**1的补码和**”。如果结果为全**1**（补码算法中的**0**），即通过校验（判断收到的数据是正确的）

校验和计算示例

4	5	0	28	
1			0	0
4	17		0	
10.12.14.5				
12.6.7.9				


4, 5, and 0	→	01000101	00000000
28	→	00000000	00011100
1	→	00000000	00000001
0 and 0	→	00000000	00000000
4 and 17	→	00000100	00010001
0	→	00000000	00000000
10.12	→	00001010	00001100
14.5	→	00001110	00000101
12.6	→	00001100	00000110
7.9	→	00000111	00001001
Sum	→	01110100	01001110
Checksum	→	10001011	10110001
		11111111	11111111



分段/分片和重装

- 问题：一个IP数据报可能经过不同的网络，不同网络的最大帧长不同
 - ◆ MTU: 最大传输单元
 - Ethernet: MTU = 1500 B
 - WiFi(IEEE802.11): MTU = 2312 B
 - ◆ MTU可能小到128字节，甚至更小
- 后果：IP应该适应不同的MTU
 - ◆ 选择合适的初始包长
 - ◆ 在经过MTU较小的网络时，将数据报分成多个包
- IP数据报可以由源主机或路径上的路由器进行分段
- IP数据报只在目的主机重装
- 片段的大小取决于最小的MTU

分段和重装：相关字段



■ 使用IP包头的字段

◆ 数据单元标识符（段标识）

- 唯一的整数，用于标识数据报
- 复制到数据报的每个片段中


◆ DF：当DF=1时，不允许分段

◆ MF：MF=0表示这是最后一个片段

◆ 偏移量


- 分段相对于原始的数据报中的位置
- 单位是 64比特（8字节）

分段示例(1)



[Stallings]

分段示例(2)



一些IP选项

■ 安全性选项

■ 严格源选路选项

- ◆ 给出源—目的地的完整路径

■ 宽松源选路

- ◆ 要求包要经过多个路由器，按照指定的顺序，允许经过路径上的其他路由器

■ 记录路由

- ◆ 告诉路径上的路由器将IP地址加到选项字段 **Tells the routers along the path to append their IP address to the option field**

■ 时间戳

- ◆ 类似路由记录选项，除了记录主机的**32**位地址之外，每个路由器还要记录**32**位的时间戳

Option	Description
Security	Specifies how secret the datagram is
Strict source routing	Gives the complete path to be followed
Loose source routing	Gives a list of routers not to be missed
Record route	Makes each router append its IP address
Timestamp	Makes each router append its address and timestamp

主要内容

- 概述
- 路由选择算法
- 拥塞控制和网络互连
- 因特网的网络层
 - ◆ IP编址
 - ◆ 包格式
 - ◆ IPv6
 - ◆ ICMP、ARP和DHCP
 - ◆ 选路协议：RIP、OSPF和BGP
 - ◆ IP组播
 - ◆ 移动IP


IPv6: 目标

- 对于快速增长的因特网及其需求，IPv4不够用
 - ◆ 在分类别地址中，传统的主机号+网络号，地址空间不够用
 - ◆ 实时应用，如视频传输要求最小时延，资源预留无法支持
 - ◆ 未提供安全机制
 - ◆ 灵活性和移动性支持有局限


IPv6: 改进

- 地址更长：128位 > 32位IPv4地址，地址空间剧增
- 简化包头：包含8个重要字段，比IPv4的13个字段少，
加快选路进程
- 更好地支持选项：对路由器简单，以加快包的处理
- 安全性：IPv6的关键特性是身份认证和私钥
- 改善QoS：以处理实时多媒体业务

IPv6: 对IPv4包头的修改



IPv6 数据报




IPv6包头：字段

- **VER**: IP版本；IPv4值为4， IPv6值为6
- **PRI**: 包的优先；0-7: 在出现拥塞时可以降低发送速率；
8-15， 用于按固定速率发送的实时业务，如音频和视频
- **流标签**: 源主机和目的主机之间的伪连接，用于预留资源和严格时延要求（仍是实验性的）
- **净荷长度**: 40字节包头之后的净荷（上层数据）的字节数
- **下一个包头**: 基本包头之后的包头，或者是IP使用的**可选扩展包头**，或者是上层协议的包头, 如UDP 和 TCP
- **跳限制**: 和IPv4的TTL目的相同
- **源地址和目的地址**: 都是128位
- **扩展包头**: 对应IPv4的选项

IPv6的扩展包头

Extension header	Description
Hop-by-hop options	Miscellaneous information for routers
Destination options	Additional information for the destination
Routing	Loose list of routers to visit
Fragmentation	Management of datagram fragments
Authentication	Verification of the sender's identity
Encrypted security payload	Information about the encrypted contents

IPv6地址：冒分十六进制



[Forouzan]

简化的IPv6地址

Unabbreviated

FDEC : BA98 : 0074 : 3210 : 000F : BBFF : 0000 : FFFF



FDEC : BA98 : 74 : 3210 : F : BBFF : 0 : FFFF

Abbreviated

Abbreviated

FDEC : 0 : 0 : 0 : 0 : BBFF : 0 : FFFF



FDEC :: BBFF : 0 : FFFF

More Abbreviated

IP包头小结

- 长度：20-60字节
- 分段：源主机/路由器分段，目的主机重装
使用“段标识、偏移量（单位为8字节）、MF”实现
- TTL：包可以继续传递的跳数，防止IP包兜圈子
- 校验和：分组累加取反，源主机/路由器/目的主机均校验，只校验IP包头

IPv6:

- 简化包头，加快路由器处理；增加对实时业务和安全支持
- 地址长度：16字节（128位），冒分十六进制

IP的设计问题


■ 设计需求：适应不同网络的差异

- ◆ 不同的编制方案
- ◆ 不同的最大包长
- ◆ 不同的网络接入机制
- ◆ 不同的超时时间
- ◆ 不同的传输模式（面向连接、无连接）
- ◆ 差错控制
- ◆ 流量控制

不同的网络接入机制

- 在网络层抽象出网络功能，依靠数据链路层提供网络接入
- 路由器 处理网络接入机制的不同

IP操作示例



[Stallings]

不同的超时时间

- 问题：不同的网络使用不同的超时机制
- 解决方案：引入数据报生命期的概念
- 数据报可能在网络中无限循环
 - ◆ 消耗资源
 - ◆ 传输协议可能需要数据报生命期的上限
- 给数据报标记生命期
 - ◆ IP数据报头字段：生命期TTL
 - ◆ 一旦生命期超期（TTL=0），数据报将路由器被丢弃，而不是转发
 - ◆ 跳计数

不同的传输模式

- 面向连接 **vs.** 无连接
- **IP**采用的是**无连接**的架构

差错控制

- 最小差错控制：只对包头进行差错检查
- 路由器通过丢包通知源主机
- 使用因特网控制报文协议**ICMP** 通知
 - ◆ **ICMP**消息封装在**IP**包中
 - ◆ 差错报告消息由路由器或目的主机发送
 - 目的地不可达
 - **TTL=0**
 - **IP**包头校验失败
 - **ICMP**重定向，告诉源主机有更好的路由
 - ...
- 非确保交付（不可靠传输）
- 可能通知高层协议

流量控制

- 允许路由器、目的主机限制输入数据的速率
- 对于无连接系统，功能有限
- 发送流量控制包（分组）
 - ◆ 请求源主机降速
- **ICMP** 消息用于流量控制
 - ◆ 源抑制报文（抑制分组）

主要内容

- 概述
- 路由选择算法
- 拥塞控制和网络互连
- 因特网的网络层
 - ◆ IP编址
 - ◆ 包格式
 - ◆ IPv6
 - ◆ ICMP、ARP和DHCP
 - ◆ 选路协议：RIP、OSPF和BGP
 - ◆ IP组播
 - ◆ 移动IP

因特网控制报文协议(ICMP)

■ 向源主机报告意外事件

◆ 目的地不可达

➤ 路由器找不到目的地

➤ IP包头**DF=1**（不可分段），但因为要转发的网络要求“小包”而无法转发

◆ 超时

➤ IP包因为**TTL=0**而被丢弃

◆ 源抑制

➤ 源主机收到此报文，应减速

◆ 重定向

➤ 路由器发现输入的数据包看起来选路错误

➤ 用于路由器通知源主机可能的选路错误

■ 也用于对因特网进行测试


◆ **ECHO**（回声）和 **ECHO** 应答： **ping**

◆ 时间戳请求和应答

◆ 路由器通告/请求：让主机发现附近的路由器

■ ICMP报文封装在IP包中

ICMP报文的格式



- ◆ ICMP报文分两类，即ICMP差错报告报文和ICMP询问报文
- ◆ ICMP 报文的前4个字节是统一的格式，共有三个字段：即类型、代码和检验和。接着的4个字节的内容与ICMP的类型有关

/谢/


ARP: 地址解析协议

■ IP地址如何映射到数据链路层地址，比如以太网地址？

- ◆ 一种方案是在系统中有一个配置文件，将IP地址映射为以太网地址
- ◆ 更好的方案是在以太网上广播一个包，询问：谁的IP地址是192.31.65.5？


A Broadcasts ARP Request

我是 192.31.65.16, 硬件地址是 00-00-C0-15-AD-18
我想知道主机 192.31.65.5 的硬件地址




B unicasts to A ARP Response

我是 192.31.65.5
硬件地址是 00-06-2B-00-EE-0A



IP 地址 vs. MAC 地址



Frame	Source IP	Source Eth.	Destination IP	Destination Eth.
Host 1 to 2, on CS net	IP1	E1	IP2	E2
Host 1 to 4, on CS net	IP1	E1	IP4	E3
Host 1 to 4, on EE net	IP1	E4	IP4	E6

IP地址全程有效，**MAC**只在一个子网内有效

RARP(逆向ARP)

■ 需求

- ◆ 已知以太网地址，对应的**IP**地址是什么？
- ◆ 示例：无盘工作站的启动

■ RARP

- ◆ 允许 workstation 在以太网上广播：我的以太网地址是**14-04-05-18-01-25**，谁知道我的**IP**地址是什么？

BOOTP(启动协议)

■ BOOTP

- ◆ 用于配置无盘工作站
- ◆ 不同于RARP, BOOTP 使用 **UDP数据报**, 在路由器上转发
- ◆ 也提供文件服务器的**IP**地址、默认路由器的**IP**地址、和网络中使用的子网掩码

■ 问题

- ◆ 需要**人工配置IP**地址和以太网地址的映射表

DHCP

■ 动态主机配置协议

- ◆ 提供远程主机的自动配置
- ◆ 包括：主机的IP地址、路由器的IP地址、子网掩码、DNS服务器的IP地址
- ◆ 是应用层协议


■ 扩展了BOOTP协议

- ◆ 在大多数系统中，已经取代了RARP和 BOOTP

■ 使用客户-服务器模式

■ 租约和更新

DHCP: IP地址分配的过程




主要内容

- 概述
- 路由选择算法
- 拥塞控制和网络互连
- 因特网的网络层
 - ◆ IP编址
 - ◆ 包格式
 - ◆ IPv6
 - ◆ ICMP、ARP和DHCP
 - ◆ 选路协议: RIP、OSPF和BGP
 - ◆ IP组播
 - ◆ 移动IP

IP的组件

源主机和路由器都要考虑路由选择





源主机如何进行路由选择？

■ 源主机将子网掩码与目的IP地址进行与操作，获得目的网络地址

◆ 如果是本网，则直接发送帧给目的主机


◆ 否则，发送帧给默认路由器



路由器如何进行路由选择？

- 通常，路由表需要至少4列：目的网络地址、子网掩码、下一跳地址和输出接口
- 当一个IP包到达，路由器将目的IP地址与子网掩码进行与操作，获得目的网络地址
- 如果在路由表里发现匹配的表项，该包将被转发到对应的输出接口
- 如果没有找到匹配表象，该包将转发到默认接口，交给默认路由器


网络特定选路 与 主机特定选路



路由表中给出目的主机地址，对于选路有更强的控制

每个网络只需要一个表项来定义网络地址。连接到同一网络的所有主机对外作为一个整体


默认/缺省路由



R1用于将包选路（转发）
给连接到N2的主机

但是，R2 作为**默认路由器**，转发给因特网其他部分的数据包，而不是列出所有的外部相关网络
对于默认路由，目的网络地址是**0.0.0.0**

路由配置示例



	Mask	Dest	Next Hop	Int.
Standard delivery	255.0.0.0	111.0.0.0	--	m0
	255.255.255.224	193.14.5.160	-	m2
	255.255.255.224	193.14.5.192	-	m1
Host-specific	255.255.255.255	194.17.21.16	111.20.18.14	m0
	255.255.255.0	192.16.7.0	111.15.17.32	m0
Network-specific	255.255.255.0	194.17.21.0	111.20.18.14	m0
	0.0.0.0	0.0.0.0	111.30.31.18	m0

示例1

路由器R1收到发给 192.16.7.14的500个包，逐行用子网掩码计算，直到找到匹配项：

Solution

规则：逐行使用路由表中的子网掩码与收到的目的地址进行“按位与”计算，看结果是否与路由表中的目的网络地址匹配。如果发现匹配，则停止。

Direct delivery

192.16.7.14 & 255.0.0.0	→ 192.0.0.0	no match	to 111.0.0.0
192.16.7.14 & 255.255.255.224	→ 192.16.7.0	no match	to 193.14.5.160
192.16.7.14 & 255.255.255.224	→ 192.16.7.	no match	to 193.14.5.192

Host-specific


192.16.7.14 & 255.255.255.255	→ 192.16.7.14	no match	to 194.17.21.16
-------------------------------	---------------	----------	-----------------

Network-specific

192.16.7.14 & 255.255.255.0	→ 192.16.7.0	match	to 192.16.7.0
-----------------------------	--------------	--------------	----------------------

示例 2

写出下图中R2的路由表



Solution

Mask	Destination	Next Hop	Int.
255.255.0.0	134.18.0.0	--	m0
255.255.0.0	129.8.0.0	222.13.16.40	m1
255.255.255.0	220.3.6.0	222.13.16.40	m1
0.0.0.0	0.0.0.0	134.18.5.2	m0

CIDR路由表

- 最长前缀匹配：对于多项匹配，选择子网掩码最长的表项
- 对于路由表中的每个表项，
 - ◆ $\text{MaskedAddress} := \text{EntryMask (bitAND) IPDatagramDestinationAddress};$
 - ◆ 如果 $(\text{MaskedAddress} == \text{EntryDestination})$ ，**标记**该表项


Mask	Destination	Next Hop
/12	128.96.0.0	145.12.56.29
/17	128.125.0.0	153.202.12.128
<u>/12</u>	<u>128.112.0.0</u>	<u>153.202.14.1</u>
/26	128.105.14.64	153.2.45.101
/32	128.105.14.66	153.2.45.101

- ◆ 示例：目的地址为**128.125.1.3**，下一跳是谁？

CIDR示例

Routing table of router in New York

Mask	Destination	Interface
/19	192.24.0.0	2
/22	192.24.12.0	1



小结：路由表查找转发过程

■ 路由表结构

目的网络IP地址	子网掩码	接口	下一跳IP地址
----------	------	----	---------

■ 路由表存在多个前缀匹配的表项(如目的IP地址192.24.12.3)


■ 扫描路由表，查找匹配的网络地址(最长匹配原则)

- ◆0项：采用默认路由，否则丢弃IP数据包并报错(ICMP)
- ◆1项：根据下一跳和接口转发
- ◆多项：选择掩码最长的一项的下一跳和接口转发

IP address/mask	Outgoing interface	Next hop
192.24.0.0/19	Port 1	XXX
192.24.8.0/21	Port 3	XXX
192.24.12.0/22	Port 2	XXX


因特网中的路由结构

- 以太网划分成很多个自治系统**AS**，由各个机构单独管理
- 每个管理机构在**AS**内部使用自己的选路协议，即**内部选路协议**
- 在**AS**之间，使用统一的选路协议，即**外部选路协议**



因特网中流行的选路协议

- **RIP**: 基于距离矢量选路
- **OSPF**: 基于链路状态选路
- **BGP**: 修改的距离矢量——路径矢量选路




[Forouzan]

RIP: 特性

- 路由信息协议
- 距离矢量选路的实现协议
- 路径开销基于跳数
 - ◆ RIP将所有网络看作平等的，穿过一个网络的开销是一样的：每个网络一跳
- 跳数的上限是16, 可扩展性差
- RIP消息在 UDP 数据报中传输
- RIPv1 不包含子网掩码
- RIPv2 支持子网掩码和下一跳地址

RIP应用示例




OSPF: 特性


- 开放的最短路径优先
- 基于 链路状态选路
- OSPF允许管理员基于所要求的服务类型来设置网络的开销
- 每个路由器在任何时候都应该有网络的确切完整拓扑
- 每个路由器需要向区内所有其他路由器通告自己的邻接情况
- OSPF 支持选路的新概念，例如：服务类型选路、负载均衡、身份认证等
- OSPF消息直接在 IP 包中传输

OSPF: 区 (Areas)


- OSPF将AS(自治系统)划分为多个区——包含路由器、主机、网络
- 骨干路由器、AS边界路由器、区边界路由器和内部路由器




OSPF: 链路类型



OSPF: 有向图表示




(a)



(b)

OSPF: 数据包



Message type	Description
Hello	Used to discover who the neighbors are
Link state update	Provides the sender's costs to its neighbors
Link state ack	Acknowledges link state update
Database description	Announces which updates the sender has
Link state request	Requests information from the partner


RIP vs. OSPF

Features	RIPv1	RIPv2	OSPF
RFC	RFC1058	RFC1723	RFC2178
Scheme	Distance-Vector		Link-state
Range of Metrics	16		65,535
Update Frequency	30s		Changes or 30mins
Dead interval	180s		Variable setting
Authentication	No	Yes	Yes
Convergence	Slow	slow	Fast
Support CIDR	No	Yes	Yes
Type of Service	No	No	Yes
Multiple paths	No	No	Yes
Ease of Use	Yes		Complex Setup

BGP

- 边界网关协议
- 路径矢量选路
- 距离矢量算法+额外的信息
 - ◆ 对于每条路由，保存完整的路径（**AS**列表）
 - ◆ 没有增加计算，只是使用额外的存储
- 优点
 - ◆ 使路由器能实现基于策略的选路
 - 例如：让路径绕开特定的**AS**
 - 例如：选路综合考虑线路速度、容量、拥趋势、整体操作质量、安全性等
 - 例如：选择经过的**AS**最少的路径
 - ◆ 容易避免环路
- BGP使用 **TCP** 承载其消息，能可靠交付

BGP示例：无环路



(a)

Information F receives
from its neighbors about D

From B: "I use BCD"
From G: "I use GCD"
From I: "I use IFGCD"
From E: "I use EFGCD"


(b)

BGP: 路由表示例

Network	Next Router	Path
N01	R01	AS14, AS23, AS67
N02	R05	AS22, AS67, AS05, AS89
N03	R06	AS67, AS89, AS09, AS34
N04	R12	AS62, AS02, AS09

[Forouzan]

BGP: 路由通告消息的传播



因特网的选路协议


	RIP	OSPF	BGP
应用范围	AS内部(IGP)	AS内部	AS之间(EGP)
选路算法	距离矢量选路	链路状态选路	路径矢量选路
路由器之间交换的信息	到各网络的跳数	网络的拓扑结构	到各网络的路径
无穷计数 (路径环路) 问题	有	无	无
路由报文 承载协议	UDP	IP	TCP

主要内容


- 概述
- 路由选择算法
- 拥塞控制和网络互连
- 因特网的网络层
 - ◆ IP编址
 - ◆ 包格式
 - ◆ IPv6
 - ◆ ICMP、ARP和DHCP
 - ◆ 选路协议：RIP、OSPF和BGP
 - ◆ IP组播
 - ◆ 移动IP

IP组播(Textbook 5.6.8)

- 组播/多播：将信息以高效的方式发给一组目的地的网络技术
 - ◆ 消息在网络的每条链路上只发送一次，仅在发往多个目的地的链路分离时才需要复制



- 组地址: D类 addresses、28位，可以有超过2.5亿个组




- 尽力而为服务

[Cisco]

IGMP

- 因特网组管理协议
- 用于在一个网络内的特定多播组里主机的成员列表
 - ◆ 在主机加入一个多播组时，发送 **IGMP** 报告消息给路由器
 - ◆ 多播路由器周期性向多播地址 **224.0.0.1** 发送 **IGMP** 询问，要求网内的各主机报告他们加入的小组信息
 - ◆ 每个主机发回 **IGMP** 报告，告知其所使用的组地址
- 定义在 **RFC 3376** 中
- **IGMP** 消息封装在 **IP** 包中

IGMP消息



[J. Liebeherr]

主要内容


- 概述
- 路由选择算法
- 拥塞控制和网络互连
- 因特网的网络层
 - ◆ IP编址
 - ◆ 包格式
 - ◆ IPv6
 - ◆ ICMP、ARP和DHCP
 - ◆ 选路协议：RIP、OSPF和BGP
 - ◆ IP组播
 - ◆ 移动IP

主要术语

- 移动节点**MN**: 移动到另外一个网络（外地网络）的主机
- 本地/归属/家乡代理**HA**: 归属网络上的路由器
- 外地代理**FA**: 外地网络上的路由器
- 关照地址**CA**: 外地代理的**IP**地址，在移动节点注册后，由外地代理发给归属代理
- 相关节点: 与移动节点通信的主机

目标：移动到外地网络中，仍然能够接收到发给原归属地**IP**地址的数据包

移动主机的选路 (Fig 5-19)



- 业务量照常发给归属子网
- 由于移动节点已经离开，归属代理拦截业务量
- 业务量通过隧道方式，发给移动节点的关照地址，然后转发给移动节点
- 移动节点发出的业务量，直接发送给相关节点
= “Triangle Routing” (三角路由)

[J. Liebeherr]

本章要点(1)

■ 网络层概述

- ◆ 物理层的位置和功能
- ◆ 虚电路交换 **vs.** 数据包选路

■ 选路算法

- ◆ 静态选路 **vs.** 动态选路
- ◆ 汇集树：衡量选路算法的标杆
- ◆ 洪泛/泛洪
- ◆ **Dijkstra** 算法
- ◆ 距离矢量选路**DVR**：特点、如何构造/更新路由表、缺点
- ◆ 链路状态选路**LSR**：特点、**LSP vs.** 拓扑结构
- ◆ 层次选路：思路

本章要点(2)

■ 拥塞控制

- ◆ 虚电路网络：接纳控制
- ◆ 数据报网络：发现拥塞、通知、发送降速
 - 抑制分组、ECN、RED

■ QoS: 令牌桶、分组调度

■ IP编制

- ◆ 分类地址：A、B、C类
- ◆ 层次地址：网络号+主机号
- ◆ 选路使用网络地址
- ◆ 子网概念
- ◆ CIDR: 前缀表示法
- ◆ 子网掩码相关计算

本章要点(3)

■ IP包格式

- ◆ 包头字段的功能
- ◆ 校验和概念
- ◆ 分段/重装

■ 选路协议：RIP, OSPF 和 BGP

- ◆ 特点和应用

■ 其他相关协议

- ◆ IPv6: 特点、地址、包头与IPv4的异同
- ◆ ICMP: 差错报告和测试
- ◆ ARP: IP address → MAC address
- ◆ DHCP: 自动分配IP地址
- ◆ IGMP: 功能——管理组成员
- ◆ 移动IP: 了解概念和思路

Terms

缩写	英文全称	中文
	adaptive algorithms	自适应算法
	addressing	寻址
	address resolution	地址解析
ARP	Address Resolution Protocol	地址解析协议
AS	Autonomous Systems	自治系统
	Admission control	接纳控制
BGP	Border Gateway Protocol	边界网关协议
	backward learning	逆向学习
	broadcast storm	广播风暴
	bridge	网桥
	broadcasting	广播
	checksum	校验和/检查和
	classful addressing	分类地址
	classless addressing	无类别地址
CIDR	Classless InterDomain Routing	无类别域间选路

缩写	英文全称	中文
	Choke Packet	抑制分组
	circuit switching	电路交换
	count-to-infinity	无穷计数
	congestion control	拥塞控制
	connectionless service	无连接服务
	connection-oriented service	面向连接的服务
	cut-through switching	直通交换
	datagram	数据报
	datagram network	数据报网络
DHCP	Dynamic Host Configuration Protocol	动态主机配置协议
	default mask	默认掩码
DVR	Distance Vector Routing	距离矢量选路
ECN	Explicit Congestion Notification	显式拥塞通知

缩写	英文全称	中文
	Ethernet	以太网
	Fair Queue	公平队列
	FIFO Queuing	先进先出队列
	Fixed Routing	固定查表选路
	flooding	洪泛
	flow control	流量控制
	forwarding	转发
	fragmentation	分段/分片
	fragmenting	分段/分片
	gateway	网关
	Hop-by-Hop	逐跳
	Hierarchical Routing	分级选路
ICMP	Internet Control Message Protocol	因特网控制报文协议
IGMP	Internet Group Management Protocol	因特网组管理协议

缩写	英文全称	中文
	implicit notification	隐式通知
	incoming interface	输入接口
	infinite loop	无限循环
	internet	互联网
	Internet	因特网
	internetworking	互通
IP	Internet Protocol	网际协议
	jitter	时延抖动
LAN	Local Area Network	局域网
	Leaky Buckets	漏桶
LSP	Link State Packet	链路状态包
LSR	Link State Routing	连路状态选路
	Longest-Prefix Matching	最长前缀匹配
MPLS	Multi-Protocol Label Switching	多协议标签交换
MTU	Maximum Transmission Unit	最大传输单元
	multicasting	多播/组播

缩写	英文全称	中文
	nonadaptive algorithms	非自适应算法
	network address	网络地址
NAT	Network Address Translation	网络地址翻译
	next hop	下一跳
	outgoing interface	输出接口
OSPF	Open Shortest Path First	开放的最短路径优先
	packet	分组/包
	packetizing	打包
	Packet Scheduling	分组调度
	packet switching	分组交换
	prefix	前缀
	Priority Queuing	优先级队列
PVR	Path Vector Routing	路径矢量选路
QoS	Quality of Service	服务质量
	re-assembly	重装

缩写	英文全称	中文
RARP	Reverse Address Resolution Protocol	逆向地址解析协议
RED	Random Early Detection	随机早期检测
	Random Routing	随机选路
	Reverse Path Forwarding	逆向路径转发
	round robin	循环
	round-trip time	环回时间
	Route Aggregation	路由聚合/会聚
RIP	Routing Information Protocol	选路信息协议
	router	路由器
	routing	选路
	routing algorithm	选路算法
	routing table	路由表
	Resource Reservation	资源预留
	Sink Tree	宿树/汇集树
	spanning tree	生成树)
	static routing	静态选路
Spring,2020	Computer Networks, Network Layer	

缩写	英文全称	中文
	store-and-forward	存储转发
	subnet	子网
	subnet mask	子网掩码
	subnetting	子网划分
	supernetting	超网划分
	supernetwork	超网
	switch	交换机
	Token Buckets	令牌桶
	Traffic Shaping	业务量(流量)整形
TTL	Time-to-Live	生命期
	Tunneling	隧道
VC	Virtual Circuit	虚电路
VCI	Virtual Circuit Identifier	虚电路标识符
	virtual circuit network	虚电路网络
WAN	Wide Area Network	广域网
WFQ	Weighted Fair Queuing	公平加权队列

Copyright Information

- Some figures used in this presentation have been either directly copied or adapted from following materials
 - ◆ Lecture notes of book "Computer Networks, a Top-down Approach", J.Kurose and W.Ross, 3rd Edition, which are marked with [Kurose]
 - ◆ "Data communications and networking", B.A.Forouzan, which are marked with [Forouzan]
 - ◆ "Data and Computer Communications", William Stallings, which are marked with [Stallings]
 - ◆ "计算机网络", 谢希仁, 第五版, 电子工业出版社, 2008年, which are marked with [谢]

Self-Study

Broadcast Routing

■ Using a spanning tree(生成树)




- ◆ Routers copy an incoming broadcast packet onto all the spanning tree lines except the one it arrived on
- ◆ Every router needs to know the spanning tree


■ Reverse Path Forwarding(逆向路径转发)

- ◆ On receiving a broadcast packet, a router checks if the packet arrived on the line normally used for **sending packets to the source** of the broadcast.
- ◆ If so, the router forwards copies of it onto all lines except the one it arrived on.
- ◆ Otherwise, the packet is discarded
- ◆ Reasonably efficient and easy to implement, routers do not need to know about spanning tree


Example of Reverse Path Forwarding



A subnet



A Sink tree
(Destination is I)



The tree built by
reverse path
forwarding.

IP地址小结

- 主机/路由器的每个网络接口有一个**IP**地址
- **IP**地址分成网络号和主机号两部分
- 一个网络内的所有**IP**地址的网络号部分一样，主机号部分不同
- 一个网络包含一组**IP**地址
 - 第一个地址（主机号部分为全**0**）是**网络地址**，代表整个网络；
路由选择使用网络地址
 - 最后一个地址（主机号部分为全**1**）是此网络的广播地址
- 分类网络：**A、B、C**三类，每类网络的大小固定，默认掩码固定
- 子网掩码：特殊的**IP**地址，网络号部分为全**1**，主机号部分为全**0**，其作用是：确定一个**IP**地址所在网络的网络地址
- 如何确定网络地址？子网掩码与已知**IP**地址“**按位与**”操作
- 划分子网：使用原网络地址中主机号的**若干高位**作为子网号

IPv6: Major Goals

- Address space
- Reduce the size of the routing tables
- Simplify the protocol, to allow routers to process packets faster
- Security
- Pay more attention to type of service, particularly for real-time data
- Multicasting
- Make it possible for a host to roam without changing its address
- Allow the protocol to evolve in the future
- Permit the old and new protocols to coexist for years

192.32.176.0/24和192.32.177.0/24聚合为一条路由表项

Routing Table

Host C

192.32.179.0/24,1,(direct)
192.32.176.0/23,1,192.32.179.1
192.32.178.0/24,1,192.32.179.1

Router R3


192.32.176.0/24,1,(direct)
192.32.177.0/24,1,192.32.176.1
192.32.178.0/24,1,192.32.176.2
192.32.179.0/24,2,(direct)

Host B

192.32.178.0/24,1,(direct)
0.0.0.0/0,1,192.32.178.1

Router R2

192.32.176.0/24,1,(direct)
192.32.177.0/24,1,192.32.176.1
192.32.178.0/24,2,(direct)
192.32.179.0/24,1,192.32.176.3



Host A

192.32.176.0/24,1,192.32.177.3
192.32.177.0/24,1,(direct)
192.32.178.0/24,1,192.32.177.3
192.32.179.0/24,1,192.32.177.3

Router R1

192.32.176.0/24,2,(direct)
192.32.177.0/24,1,(direct)
192.32.178.0/24,2,192.32.176.2
192.32.179.0/24,2,192.32.176.3

Routing Table

Host C

192.32.179.0/24,1,(direct)
 192.32.176.0/23,1,192.32.179.1 11000000.00100000.1011000x.xxxxxxxx
 192.32.178.0/24,1,192.32.179.1

Router R3


192.32.176.0/24,1,(direct)
 192.32.177.0/24,1,192.32.176.1
 192.32.178.0/24,1,192.32.176.2
 192.32.179.0/24,2,(direct)

Host B


192.32.178.0/24,1,(direct)
 0.0.0.0/0,1,192.32.178.1
 11000000.00100000.10110010.xxxxxxxx
 xxxxxxxx.xxxxxxxx.xxxxxxxx.xxxxxxxx

Router R2

192.32.176.0/24,1,(direct)
 192.32.177.0/24,1,192.32.176.1
 192.32.178.0/24,2,(direct)
 192.32.179.0/24,1,192.32.176.3



举例：动态NAT表项



■ A: 发送TCP报 10.0.0.1:3723->18.7.22.83:80

■ R: 路由器动态创建**NAT**表项:

(Local)10.0.0.1:3723—(Global)123.116.156.133:33120—(Peer)18.7.22.83:80

改TCP报为123.116.156.133:33120->18.7.22.83:80

■ S: 服务器S回数据18.7.22.83:80->123.116.156.133:33120

■ R: 查NAT表: 改TCP报为为18.7.22.83:80->10.0.0.1:3723


■ A: 收到数据包18.7.22.83:80->10.0.0.1:3723

(连接过程中使用该**NAT**表项, 当连接关闭时或长久未用的**NAT**表项, 删除)

OUT: (SRC)10.0.0.1:3723—(DST)18.7.22.83:80=>(SRC)123.116.156.133:33120

IN: (SRC)18.7.22.83:80—(DST)123.116.156.133:33120=>(DST)10.0.0.1:3723

举例：静态NAT表项




- R: 设10.0.0.7为Web服务器: 建立静态**NAT**表
(Local)10.0.0.7:8080—(Global)123.116.156.133:80 —(Peer)*:*
- C: 因特网上的客户端C发送TCP数据包:
17.1.1.10:3598->123.116.156.133:80
- R: 查 NAT表, 改为17.1.1.10:3598->10.0.0.7:8080
- W: Web服务器回数据10.0.0.7:8080->17.1.1.10:3598
- R: 查 NAT表, 改为123.116.156.133:80->17.1.1.10:3598
- C: 收到返回TCP数据报123.116.156.133:80->17.1.1.10:3598

DHCP Client-Server Scenario


DHCP server: 223.1.2.5

Arriving
client




DHCP Relay Agent(DHCP中继代理)


- When this is no DHCP server in the LAN, DHCP relay agent relays DHCP messages between DHCP clients and DHCP server




Hierarchical routing in Internet




Multicast Routing: Using Group Spanning Trees (Figure 5-16)




A Network



A Spanning Tree of
Leftmost Router



Multicast Tree for Group 1



Multicast Tree for Group 2